

HỌC MÁY CƠ BẢN

TẬP CHUẨN BỊ TRƯỚC BUỔI HỌC

Mười buổi · mỗi buổi 150 phút

Giảng viên: PGS.TS. Nguyễn Văn Hậu

DÙNG TẬP NÀY THẾ NÀO

Mỗi buổi học có **đúng một trang**. Đọc trang đó **trước khi lên lớp 3–5 ngày**, mất khoảng 5 phút.

Mục quan trọng nhất là **CẦN ÔN LẠI**. Ba câu tự kiểm ở đó không phải bài tập — chúng là phép thử xem bạn đã sẵn sàng chưa. **Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.**

Mục **NGHĨ TRƯỚC** chỉ có một câu hỏi và **không có đáp án**. Hãy viết câu trả lời của bạn ra giấy và mang theo. Trong buổi học sẽ có lúc bạn đối chiếu với chính chữ mình đã viết — đoán sai không sao, nhưng phải đoán trước khi biết.

Phụ lục A ở cuối tập liệt kê kết quả chính của cả mười buổi. Nó dùng để **ôn lại sau buổi học**, không phải để đọc trước. Đọc trước thì mất hết phần thú vị.

Phụ lục B là bảng tra thuật ngữ Việt–Anh của toàn học phần.

MƯỜI BUỔI TRÊN MỘT BẢN ĐỒ

Học phân đi theo một mạch: mỗi buổi trả lời một câu hỏi mà buổi trước để lại.

Buổi	Tên buổi	Nội dung chính	Câu hỏi của buổi
1	“Hợp gu” là một phép tính	Vector và độ tương đồng cosine	Làm thế nào biến “phim hợp gu” thành một phép tính?
2	Đoán loài chim bằng ba người hàng xóm	Quy trình học máy đầu tiên và thuật toán k-NN	Từ bốn con số đo được trên một con chim chưa biết loài, máy quyết định nhãn bằng cách nào?
3	Đúng nhiều hơn, bán được ít hơn	Ma trận nhầm lẫn, bốn chỉ số và khả năng tổng quát hoá	Khi “đúng bao nhiêu phần trăm” không phải câu ngân hàng hỏi, ta đo một mô hình bằng cái gì?
4	Bước dài bao nhiêu thì tới đáy?	Hồi quy tuyến tính và thuật toán xuống dốc (Gradient Descent)	Không ai cho sẵn độ dốc và hệ số chặn của đường thẳng — máy tự đi tìm chúng bằng cách nào?
5	Mỗi giờ học thêm, cơ hội nhân đôi	Hồi quy logistic · phân loại bằng xác suất	Thuật toán xuống dốc chạy được với mọi hàm mất mát khả vi — vậy lấy tư cách gì để chọn ra đúng một hàm?
6	Hỏi ít câu hơn, đoán đúng hơn	Cây quyết định · cắt tia · rừng ngẫu nhiên	Máy dựa vào đâu để biết câu hỏi nào đáng hỏi trước, và tới câu thứ mấy thì phải thôi hỏi?
7	Đúng một trăm phần trăm, sai từ đâu	Rò rỉ dữ liệu · chia tập đúng cách · đánh giá trung thực	Con số ta đọc trên tập kiểm tra có thật sự là năng lực của mô hình không?
8	Máy chọn hai, người chọn bốn	Phân cụm K-means · phân khúc khách hàng RFM · chọn số cụm khi không có nhãn	Khi dữ liệu không có nhãn, ai phán xử một cách chia là tốt, và dựa vào căn cứ nào?
9	Bỏ chín phần mười, giữ chín phần mười	Phân tích thành phần chính (PCA) · giảm chiều · nhận dạng hoạt động từ điện thoại	Có thể thay 561 tọa độ bằng một số ít tọa độ mới mà vẫn giữ được cấu trúc quan trọng không?
10	Hơn đúng một mẫu, hay hơn năm trăm mẫu?	Mạng neuron nhiều lớp · học biểu diễn · khi nào thì đáng	Làm thế nào một mô hình học được biểu diễn tốt hơn thứ ta đưa cho nó?

HAI ĐIỀU XUYÊN SUỐT CẢ MƯỜI BUỔI

Mọi con số trên slide đều được đo, không chép từ tài liệu nào. Bạn có quyền hỏi con số đó đo thế nào.

Mỗi buổi đều có phần tính bằng bút trước khi chạm vào máy. Đó là cách duy nhất để sau này bạn kiểm được máy có sai không. Hãy luôn mang giấy và bút.

BUỔI 1

“Hợp gu” là một phép tính

Vector và độ tương đồng cosine

CÂU HỎI CỦA BUỔI

Làm thế nào biến “phim hợp gu” thành một phép tính?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **DỤNG** một bộ phim thành vector multi-hot và chỉ ra thông tin nào bị vứt bỏ khi làm vậy.
- ▶ **TÍNH** bằng tay chuẩn, tích vô hướng và cosine cho năm bộ phim, rồi tự kiểm bằng phép cộng theo hai đường độc lập.
- ▶ **GIẢI THÍCH** vì sao chia cho chuẩn làm đổi thứ hạng, và chỉ ra khi nào thêm một thể loại làm cosine tăng, khi nào làm nó giảm.
- ▶ **VIẾT** hàm cosine bằng NumPy, đối chiếu với hàm có sẵn của thư viện và giải thích chênh lệch cực nhỏ giữa hai bên.
- ▶ **CHỈ RA** hai lý do khiến một gợi ý có cosine cao vẫn có thể là gợi ý tồi, kèm bằng chứng bằng số.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Toán nền	vector và cộng vector — hôm nay mỗi phim là một vector	Cộng hai vector (1, 0, 1) và (0, 1, 1) thì được vector nào?
Toán nền	phân số, quy đồng mẫu số và căn bậc hai	Không dùng máy tính: giữa 3/4 và 5/8, phân số nào lớn hơn?
Lập trình nền	Python: list, vòng lặp for, đọc một tệp văn bản	Trong Python, lệnh nào cho biết một list có bao nhiêu phần tử?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn tính tay trên một bảng năm bộ phim của MovieLens-1M: mỗi phim là một vector ba chiều Action · Comedy · Sci-Fi, đối chiếu với một hồ sơ người dùng cũng ba chiều. Sáu bước, giữ nguyên dạng phân số, chỉ dùng máy tính bỏ túi ở bước cuối cùng.

Dữ liệu thật: Bộ dữ liệu MovieLens-1M của GroupLens: 3.883 phim trong movies.dat, 6.040 người dùng, 1.000.209 lượt đánh giá, 18 nhãn thể loại. Phần cuối buổi chạy trên hồ sơ có thật của người dùng số 833, dựng lại từ các phim người này chấm từ 4 sao trở lên.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Nếu phải mô tả một bộ phim bằng đúng ba con số, bạn sẽ chọn ba con số nào?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy, bút và máy tính bỏ túi cho ba mươi phút tính tay; thêm laptop có Python và NumPy để chạy phần cuối buổi.

TỪ KHOÁ

vector (vector) · số chiều (dimension) · mã hoá một-nóng (one-hot) · mã hoá nhiều-nóng (multi-hot) · tích vô hướng (dot product) · chuẩn L2 (L2 norm) · chuẩn hoá (normalization) · độ tương đồng cosine (cosine similarity) · biểu diễn dữ liệu (representation) · hồ sơ người dùng (user profile) · xếp hạng top-N (top-N ranking) · người dùng mới chưa có dữ liệu (cold start)

BUỔI 2

Đoán loài chim bằng ba người hàng xóm

Quy trình học máy đầu tiên và thuật toán k -NN

CÂU HỎI CỦA BUỔI

Từ bốn con số đo được trên một con chim chưa biết loài, máy quyết định nhãn bằng cách nào?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **DỰNG** trọn một quy trình học máy năm bước: chia dữ liệu, chọn đặc trưng, chuẩn hoá, dự đoán, đánh giá.
- ▶ **TÍNH** bằng tay sáu khoảng cách, xếp hạng và bỏ phiếu k -NN trên ba thang đo khác nhau, rồi tự kiểm tổng hai cột bằng hai đường độc lập.
- ▶ **CHỈ RA** trên chính bảng tính tay của bạn, đơn vị đo tác động ra sao tới nhãn mà thuật toán trả về, kèm bằng chứng bằng số.
- ▶ **CHỌN** một giá trị k bằng bằng chứng chứ không bằng cảm tính, và nêu được điều gì hỏng khi k quá nhỏ và khi k quá lớn.
- ▶ **LIỆT KÊ** ba lý do khiến k -NN trả về nhãn sai, kèm bằng chứng bằng số trên bộ dữ liệu chim thật.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 1	cosine đo “giống nhau” bằng góc — hôm nay ta đổi thước	Trong công thức cosine, tích vô hướng được chia cho hai đại lượng nào?
Bài 1	phép kiểm tổng theo hai đường độc lập — hôm nay dùng lại	Ở Bài 1, bạn cộng tổng tích vô hướng theo hai đường nào để tự bắt lỗi?
Toán nền	định lý Pythagoras, bình phương và phần trăm của một tổng	Tam giác vuông có hai cạnh góc vuông 3 và 4 thì cạnh huyền dài bao nhiêu?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn tính tay trên bảy con chim cánh cụt có thật: sáu con đã biết loài và một con cần đoán, mỗi con hai phép đo — chiều dài vây (mm) và khối lượng (g). Ba vòng tính trên ba thang đo, mười tám phép tính, các con số được chọn để tính nhằm được nên gần như không phải bấm máy.

Dữ liệu thật: Chim cánh cụt Palmer, tệp penguins.csv: 344 dòng thu tại Trạm Palmer LTER, Nam Cực, 2007–2009; hai dòng thiếu số đo bị loại, còn 342 con dùng được — Adelie 151, Gentoo 123, Chinstrap 68. Mỗi con bốn phép đo (dài mỏ, dày mỏ, dài vây, khối lượng) và một nhãn loài do nhà sinh học ghi tại thực địa. Chia 70/30 phân tầng, hạt ngẫu nhiên cố định: 239 con huấn luyện, 103 con kiểm tra.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Bạn có sáu con chim đã biết loài và một con chưa biết — bạn sẽ đoán loài con đó bằng cách nào?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy và bút cho ba mươi phút tính tay, máy tính bỏ túi để dự phòng; thêm laptop có Python và trình duyệt mở sẵn Colab cho phần sau giờ nghỉ.

TỪ KHOÁ

phân loại (classification) · k láng giềng gần nhất (k -nearest neighbours) · khoảng cách Euclid (Euclidean distance) · khoảng cách Manhattan (Manhattan distance) · đặc trưng (feature) · chuẩn hoá (normalization) · tập huấn luyện (training set) · tập kiểm tra (test set) · bỏ phiếu đa số (majority vote) · siêu tham số (hyperparameter) · độ chính xác (accuracy) · độ bao phủ của một lớp (recall)

BUỔI 3

Đúng nhiều hơn, bán được ít hơn

Ma trận nhầm lẫn, bốn chỉ số và khả năng tổng quát hoá

CÂU HỎI CỦA BUỔI

Khi “đúng bao nhiêu phần trăm” không phải câu ngân hàng hỏi, ta đo một mô hình bằng cái gì?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **VẼ** và đọc được bảng đếm bốn ô của một mô hình phân loại, gọi tên từng ô bằng ngôn ngữ bài toán chứ không bằng chữ viết tắt.
- ▶ **TÍNH** bằng tay bốn chỉ số accuracy, precision, recall và F1 trên phân số tối giản, rồi tự kiểm bằng ba đường độc lập cùng ra một số.
- ▶ **CHỈ RA** bằng chính con số bạn vừa tính, một mô hình có accuracy cao hơn và F1 bằng nhau mà lại mang về ít hợp đồng hơn.
- ▶ **GIẢI THÍCH** vì sao một chỉ số dao động ít hơn giữa các lần chia dữ liệu không có nghĩa là nó đo tốt hơn.
- ▶ **CHỌN** ngưỡng quyết định từ tỉ số giữa lợi nhuận một hợp đồng và chi phí một cuộc gọi, và nói được ngưỡng đổi ra sao khi tỉ số đổi.
- ▶ **CHỈ RA** hai lý do khiến một mô hình đang đo rất khá tụt hẳn năng lực khi ta đổi cách chia dữ liệu theo thời gian.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 2	độ chính xác trên tập kiểm tra — hôm nay ta bắt lỗi nó	Ở Bài 2, độ chính xác được tính trên tập nào và bằng phép chia nào?
Bài 2	k láng giềng gần nhất và bỏ phiếu đa số	Với $k = 3$, k-NN dùng quy tắc nào để chọn nhãn cho một con chim chưa biết loài?
Bài 2	chia 70/30 phân tầng và kiểm định chéo 5 phần	Vì sao ở Bài 2 ta không được đo mô hình trên chính dữ liệu đã dùng để học?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn tính tay trên một bảng đếm 100 khách hàng, cùng một mô hình nhưng cắt ở hai ngưỡng khác nhau: mỗi ngưỡng bốn ô, tất cả là tám con số. Từ tám con số đó bạn tính bốn chỉ số cho mỗi ngưỡng, viết ở dạng phân số tối giản; các số được chọn sao cho mọi phép tính chạy trên số nguyên nên gần như không phải bấm máy. Khoảng ba mươi phút giấy bút liên tục.

Dữ liệu thật: Bank Marketing của UCI, tệp bank-additional-full.csv: 41.188 cuộc gọi telesales của một ngân hàng Bồ Đào Nha, thu từ tháng 5/2008 đến tháng 11/2010, mỗi cuộc gọi một dòng, 21 cột — 10 cột số, 10 cột chữ và một nhãn có/không. Tập kiểm tra gồm 12.357 khách. Trong tệp có 12 dòng trùng nhau hoàn toàn và 12.718 ô ghi “unknown” — đó là giá trị có nghĩa, không phải ô trống.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Nếu tổng đài gọi cho nhiều khách hơn, ngân hàng được thêm gì và mất thêm gì?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy và bút là chính, vì phần dài nhất của buổi là tính tay trên phân số; máy tính bỏ túi chỉ để dự phòng, mọi phép chia đều ra số nguyên. Phần sau giờ nghỉ cần laptop có Python và trình duyệt mở sẵn Colab.

TỪ KHOÁ

ma trận nhầm lẫn (confusion matrix) · dương tính giả (false positive) · âm tính giả (false negative) · độ chính xác (accuracy) · độ chuẩn xác (precision) · độ bao phủ (recall) · điểm F1 (F1 score) · trung bình điều hoà (harmonic mean) · ngưỡng quyết định (decision threshold) · mô hình cơ sở (baseline) · dữ liệu mất cân bằng (imbalanced data) · khả năng tổng quát hoá (generalization)

BUỔI 4

Bước dài bao nhiêu thì tới đáy?

Hồi quy tuyến tính và thuật toán xuống dốc (Gradient Descent)

CÂU HỎI CỦA BUỔI

Không ai cho sẵn độ dốc và hệ số chặn của đường thẳng — máy tự đi tìm chúng bằng cách nào?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **TÍNH** bằng tay hai tham số của đường thẳng tốt nhất trên bốn căn nhà, rồi tự kiểm lại bằng hai phương trình chuẩn tắc.
- ▶ **TÍNH** bằng bút bốn bước đầu của thuật toán xuống dốc, rồi rút ra công thức cho biết sai số co lại bao nhiêu lần sau mỗi bước.
- ▶ **VIẾT** ra giá trị tham số ở bước lặp thứ k bất kỳ mà không phải chạy đủ k bước.
- ▶ **CHỈ RA** bằng số cái ngưỡng của độ dài bước mà vượt qua nó thì thuật toán không bao giờ tới đáy, dù chạy bao nhiêu bước.
- ▶ **GIẢI THÍCH** vì sao việc trừ trung bình và chia độ lệch chuẩn của đặc trưng làm thuật toán chạy nhanh lên, bằng độ dẹt của mặt lồi.
- ▶ **CHỈ RA** một trường hợp hai thước đo sai lệch cùng đo trên một bộ dữ liệu mà lại chọn ra hai đường hồi quy khác nhau.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 3	ma trận nhầm lẫn và bốn chỉ số — hôm nay chúng hết dùng	Bốn ô của ma trận nhầm lẫn ở Bài 3 đếm những gì?
Bài 3	mốc so sánh tầm thường: mô hình luôn đoán lớp đa số	Vì sao ở Bài 3 một mô hình luôn đoán lớp đa số vẫn đạt độ chính xác rất cao?
Toán nền	đạo hàm đa thức bậc hai, đỉnh parabol, hệ số góc	Đạo hàm của $y = 3x^2 - 12x$ bằng bao nhiêu, và nó bằng 0 tại x nào?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn tính tay trên bốn căn nhà, mỗi căn một cặp số nguyên diện tích – giá, tất cả là tám con số; từ tám con số đó dựng hàm mất mát, lấy đạo hàm, rồi chạy bằng bút bốn bước xuống dốc cho năm giá trị độ dài bước khác nhau, và tính thêm một bảng vuông bốn ô mô tả hình dạng mặt lồi. Bộ số được chọn để mọi bước ra phân số tối giản nên gần như không phải bấm máy; khoảng năm mươi phút giấy bút liên tục, chia làm hai chặng.

Dữ liệu thật: California Housing: 20.640 dòng, mỗi dòng là một nhóm nhà ở của cuộc điều tra dân số Hoa Kỳ năm 1990 (khoảng 600–3.000 người), gốc từ Pace và Barry (1997), Statistics & Probability Letters 33(3), 291–297. Bài này chỉ dùng 2 trong 10 cột — thu nhập trung vị và giá nhà trung vị — và 965 dòng có giá ghi đúng ở mức trên 500.001 đô la. Bản tệp phổ biến trên GitHub đã bị người khác sửa hai chỗ; cả hai chỗ đó bài này đều không dùng.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Nếu cứ tăng dần độ dài mỗi bước chân, thuật toán có tới đáy nhanh dần mãi không, hay tới lúc nào đó hỏng?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy và bút là chính, mang nhiều giấy nháp: hơn một nửa buổi là tính tay trên phân số và vẽ tay đường đi của thuật toán. Máy tính bỏ túi chỉ cần cho một phép căn bậc hai. Phần cuối buổi cần laptop có Python và trình duyệt mở sẵn Colab để kiểm lại trên dữ liệu thật.

TỪ KHOÁ

hồi quy tuyến tính (linear regression) · phần dư (residual) · hàm mất mát (loss function) · sai số bình phương trung bình (mean squared error) · sai lệch tuyệt đối trung bình (mean absolute error) · hệ số xác định (coefficient of determination) · nghiệm đóng (closed-form solution) · thuật toán xuống dốc (gradient descent) · tốc độ học (độ dài bước) (learning rate) · đạo hàm riêng (partial derivative) · ma trận Hessian (Hessian matrix) · điều kiện số (condition number)

BUỔI 5

Mỗi giờ học thêm, cơ hội nhân đôi

Hồi quy logistic · phân loại bằng xác suất

CÂU HỎI CỦA BUỔI

Thuật toán xuống dốc chạy được với mọi hàm mất mát khả vi — vậy lấy tư cách gì để chọn ra đúng một hàm?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **TÍNH** bằng bút, chuyển một bảng tần số qua lại giữa ba thang đo: xác suất, odds và log-odds.
- ▶ **ĐỌC** hệ số của mô hình thành một câu nói về tỉ số odds đúng ngữ pháp, và chỉ ra câu nào nói sai.
- ▶ **KIỂM** chỉ bằng cách đếm, không dùng máy tính, xem một nghiệm đã là nghiệm hợp lý cực đại hay chưa.
- ▶ **CHỨNG MINH** rằng đạo hàm của log-loss rút gọn thành sai số dự đoán nhân đặc trưng, và vì sao dùng MSE thì đạo hàm ấy bị bóp nhỏ.
- ▶ **PHÂN BIỆT** khả năng xếp hạng đúng thứ tự với chất lượng của chính con số xác suất, bằng ba thước đo khác nhau.
- ▶ **CHỈ RA** bốn cách mà hồi quy logistic hỏng, mỗi cách kèm một dấu hiệu nhận biết cụ thể, đo được.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 4	vòng lặp xuống dốc và tốc độ học — hôm nay dùng lại y nguyên	Ở Bài 4, sau mỗi bước xuống dốc bạn cập nhật tham số w bằng công thức nào?
Bài 4	MSE và điều kiện để một hàm mất mát chạy được với xuống dốc	Ở Bài 4, sai số bình phương trung bình MSE được tính bằng công thức nào?
Toán nền	logarit, hàm mũ và đạo hàm của hàm hợp	$\ln(a/b)$ viết lại thành gì, và đạo hàm của $f(g(x))$ tính theo công thức nào?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn tính tay trên 19 sinh viên chia làm bốn nhóm theo số giờ tự học thêm — 0, 1, 2 và 3 giờ; từ bảng tần số ấy bạn tự chuyển sang odds rồi sang log-odds, đọc thẳng ra hai tham số của mô hình, tính ngược lại xác suất của từng nhóm, rồi kiểm hai phương trình cân bằng chỉ bằng cách đếm. Bộ số được chọn để mọi phép tính ra phân số tối giản, nên gần như không phải bấm máy; khoảng 26 phút giấy bút liên tục. Chỉ sau khi tính xong bằng tay mới mở máy đối chiếu.

Dữ liệu thật: Bank Marketing của UCI Machine Learning Repository (Moro, Cortez, Rita): 41.188 khách hàng, 21 cột, từ một chiến dịch tiếp thị qua điện thoại của một ngân hàng Bồ Đào Nha; nhân là khách có đăng ký tiền gửi có kỳ hạn hay không. Đúng bộ dữ liệu và đúng phép chia của Bài 3: 9 cột số, chia phân tầng 70/30, tập kiểm tra 12.357 khách. Cột độ dài cuộc gọi bị loại có chủ ý vì nó chỉ biết được sau khi đã biết kết quả — một ví dụ mẫu về rò rỉ dữ liệu.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Vẽ một đường thẳng qua các điểm nhãn 0 và 1: dự đoán của nó có thể vượt quá 1 không, và khi đó đọc thế nào?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy và bút là chính: hơn một phần tư buổi là tính tay trên phân số, mang nhiều giấy nháp. Máy tính bỏ túi cần có phím logarit tự nhiên và phím e mũ, dùng cho bảng chuyển thang đo. Phần cuối buổi cần laptop có Python với numpy và scikit-learn, hoặc trình duyệt mở sẵn Colab.

TỪ KHOA

hồi quy logistic (logistic regression) · odds · log-odds (logit) · hàm sigmoid (sigmoid function) · hợp lý cực đại (maximum likelihood) · log-loss (entropy chéo nhị phân) (binary cross-entropy) · tỉ số odds (odds ratio) · phương trình điểm số (score equations) · ranh giới quyết định (decision boundary) · hiệu chuẩn (calibration) · tách hoàn hảo (separation) · chính quy hoá (regularization)

BUỔI 6

Hỏi ít câu hơn, đoán đúng hơn

Cây quyết định · cắt tỉa · rừng ngẫu nhiên

CÂU HỎI CỦA BUỔI

Máy dựa vào đâu để biết câu hỏi nào đáng hỏi trước, và tới câu thứ mấy thì phải thôi hỏi?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **TÍNH** bằng bút chỉ số Gini của một nút và độ giảm tạp chất có trọng số của một nhát cắt bất kỳ, ra phân số tối giản.
- ▶ **CHỌN** ngưỡng tốt nhất của một đặc trưng bằng cách duyệt hết, và nói được vì sao chỉ cần thử trung điểm giữa hai giá trị liên tiếp.
- ▶ **KIỂM** một cây đã dựng bằng luật bảo toàn — cộng đóng góp của mọi nút trong rồi đối chiếu với nút gốc — không cần máy tính.
- ▶ **DỰNG** lại con số tầm quan trọng của đặc trưng mà thư viện in ra, từ chính cây mình vừa vẽ, và chỉ ra hai lý do nó có thể đánh lừa.
- ▶ **ĐỌC** đường cong theo độ sâu và theo mức cắt tỉa, rồi giải thích vì sao kết quả đo trên chính dữ liệu đã học không tự nó tố cáo một mô hình tồi.
- ▶ **CHỈ RA** bốn cách cây quyết định hỏng, mỗi cách kèm một dấu hiệu nhận biết đo được.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 5	ranh giới của hồi quy logistic luôn là một đường thẳng	Ở Bài 5, tập các điểm mà mô hình cho xác suất đúng bằng một nửa có hình gì?
Bài 5	chính quy hoá L2 và tham số C — hôm nay nó đổi tên	Ở Bài 5, C nhỏ đi thì khoản phạt đặt lên hệ số w nặng hơn hay nhẹ hơn?
Bài 3	ma trận nhầm lẫn, F_1 và kiểm định chéo 5 phần	Ở Bài 3, F_1 được tính từ precision và recall bằng công thức nào?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn tính tay trên 16 hạt đậu — 8 hạt giống SEKER, 8 hạt giống HOROZ — với đúng hai phép đo: chiều dài hạt và độ tròn hạt. Mỗi đặc trưng phải thử 15 ngưỡng, lớp chia đôi rồi ghép kết quả. Khoảng 28 phút giấy bút; mọi số giữ ở dạng phân số mẫu ≤ 25 nên hầu như không phải bấm máy.

Dữ liệu thật: Dry Bean Dataset, UCI bộ số 602 (Koklu và Özkan, 2020; CC BY 4.0): 13.611 hạt đậu chụp bằng camera, 16 phép đo hình học, 7 giống. Không ô thiếu nhưng có 68 hàng trùng hoàn toàn. Chia phân tầng 80/20: 10.888 hạt học, 2.723 hạt kiểm. Trang mô tả của UCI có hai chỗ không khớp với chính tệp dữ liệu.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Để tách hai giống đậu SEKER và HOROZ, câu hỏi đầu tiên nên hỏi về chiều dài của hạt hay về độ tròn của hạt?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy nháp (mang nhiều), bút, thêm bút chì và thước để kẻ nhát cắt. Máy tính bỏ túi gần như không cần. Nửa sau cần laptop có Python với numpy và scikit-learn, hoặc Colab.

TỪ KHOÁ

cây quyết định (decision tree) · chỉ số Gini (Gini impurity) · độ lợi thông tin (information gain) · nhát cắt vuông góc trục (axis-aligned split) · thuật toán tham lam (greedy algorithm) · quá khớp (overfitting) · cắt tỉa (pruning) · tầm quan trọng của đặc trưng (feature importance) · rừng ngẫu nhiên (random forest) · lấy mẫu có hoàn lại (bootstrap) · kiểm định chéo (cross-validation) · bất biến với biến đổi đơn điệu (monotone invariance)

BUỔI 7

Đúng một trăm phần trăm, sai từ đầu

Rò rỉ dữ liệu · chia tập đúng cách · đánh giá trung thực

CÂU HỎI CỦA BUỔI

Con số ta đọc trên tập kiểm tra có thật sự là năng lực của mô hình không?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **ÁP DỤNG** bảng kiểm năm câu hỏi cho từng cột dữ liệu và ra quyết định giữ hay loại, mỗi quyết định kèm căn cứ viết ra được.
- ▶ **PHÁT HIỆN** một cột đã chứa sẵn đáp án bằng bảng chéo với nhãn, và giải thích vì sao phép kiểm ấy không đủ để tuyên bố các cột còn lại là sạch.
- ▶ **CHỌN** cách chia dữ liệu khớp với tình huống mà mô hình sẽ gặp lúc triển khai, và định lượng thiệt hại khi chọn sai.
- ▶ **ĐO** ảnh hưởng của hàng trùng lặp tới ước lượng hiệu năng, và chỉ ra vì sao hai họ mô hình chịu thiệt khác nhau.
- ▶ **XẾP HẠNG** năm kiểu rò rỉ theo thiệt hại đo được, thay vì theo mức độ chúng được nhắc tới trong sách vở.
- ▶ **PHÂN BIỆT** quá khớp với rò rỉ bằng dấu hiệu đo được: một bên làm điểm kiểm tra xấu đi, bên kia làm nó đẹp lên.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 6	khoảng cách giữa điểm huấn luyện và điểm kiểm tra	Ở Bài 6, cái gì tố cáo một cây quá khớp: điểm huấn luyện hay khoảng cách hai điểm?
Bài 6	ưu thế của rừng so với cây — hôm nay ta đo lại nó	Ở Bài 6, rừng ngẫu nhiên hơn một cây đã cắt tia ở chỗ nào, và đổi lại mất gì?
Bài 6	quét ngưỡng một cột số — hôm nay dùng lại nguyên vẹn	Ở Bài 6, để tìm ngưỡng tốt nhất của một cột số, bạn phải thử những giá trị nào?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Hiện vật của buổi không phải phép tính mà là một BẢNG KIỂM năm câu hỏi: bạn tự điền nó cho bốn cột của một bảng 12 đặt phòng, mỗi ô một câu trả lời kèm căn cứ, ra bốn quyết định giữ hoặc loại. Kèm ba phép đếm bằng mắt trên đúng 12 dòng ấy. Khoảng 29 phút giấy bút, không cần máy tính bỏ túi.

Dữ liệu thật: Hotel booking demand: 119.390 đặt phòng thật, 32 cột, gộp từ hai khách sạn (40.060 và 79.330 đơn) trong 26 tháng, 07/2015–08/2017. Nguồn: Antonio, de Almeida, Nunes (2019), Data in Brief 22, 41–49, DOI 10.1016/j.dib.2018.11.126. Tập có ô thiếu ở bốn cột, có 31.994 hàng trùng hoàn toàn, và không có mã đặt phòng để phân biệt hai đơn giống hệt nhau.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Nhìn bốn cột của bảng mười hai đặt phòng: cột nào khiến bạn thấy gợn, và vì sao lại là cột đó?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy bút là chính (mang nhiều giấy), thêm hai màu bút để đánh dấu cột giữ và cột loại. Nửa sau cần laptop có Python với pandas và scikit-learn, hoặc Colab.

TỪ KHOA

rò rỉ dữ liệu (data leakage) · bảng chéo (crosstab) · chia theo thời gian (time-based split) · chia phân tầng (stratified split) · hàng trùng lặp (duplicate rows) · dây chuyền xử lý (Pipeline) · chuẩn hoá (StandardScaler) · điền khuyết (imputation) · kiểm chứng chéo (cross-validation) · dịch chuyển phân phối (distribution shift) · mã hoá one-hot (one-hot encoding) · mã hoá mục tiêu (target encoding)

BUỔI 8

Máy chọn hai, người chọn bốn

Phân cụm K-means · phân khúc khách hàng RFM · chọn số cụm khi không có nhãn

CÂU HỎI CỦA BUỔI

Khi dữ liệu không có nhãn, ai phán xử một cách chia là tốt, và dựa vào căn cứ nào?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **VIẾT** đúng công thức của đại lượng mà thuật toán tối thiểu hoá, và giải thích vì sao bước cập nhật lấy trung bình toạ độ.
- ▶ **TÍNH** tròn hai vòng thuật toán bằng tay trên sáu khách hàng, rồi tự kiểm bằng hai bất biến làm được bằng mắt và bút.
- ▶ **CHỨNG MINH** bằng thí nghiệm rằng cùng dữ liệu và cùng số cụm vẫn cho nhiều kết quả khác nhau tùy điểm xuất phát, và đo mức thiệt hại.
- ▶ **GIẢI THÍCH** vì sao đại lượng ấy luôn giảm khi số cụm tăng, và vì vậy một mình nó không bao giờ chọn được số cụm.
- ▶ **SO SÁNH** bốn tiêu chí chọn số cụm — độ chặt, độ tách, độ ổn định, ràng buộc nghiệp vụ — và chỉ ra điểm mù của từng cái.
- ▶ **ĐO** ảnh hưởng của bước chuẩn hoá lên tỉ trọng của ba trục và lên điểm số mà thước đo hình học chấm cho cách chia.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 7	hai câu hỏi Bài 7 để lại — hôm nay trả cả hai	Bài 7 kết thúc bằng hai câu hỏi còn treo. Bạn nhắc lại được cả hai không?
Bài 7	accuracy, F1, AUC — cả ba chỉ tính được khi có cột nhãn	Muốn tính accuracy, bảng dữ liệu bắt buộc phải có thêm cột gì ngoài các cột đặc trưng?
Bài 2	khoảng cách Euclid và thang đo — hôm nay dùng lại nguyên vẹn	Ở Bài 2, đổi đơn vị một trục từ gam sang kilôgam thì khoảng cách Euclid đổi thế nào?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn chạy thuật toán bằng tay trên sáu khách hàng đặt trên mặt phẳng hai trục — số đơn hàng và chi tiêu, toạ độ đều nguyên. Hai nhóm, hai tâm ban đầu đặt trùng hai khách cụ thể, lập hai vòng, mỗi vòng 12 phép tính khoảng cách. Sau đó cả lớp chia nhau vét đủ 20 cách chọn ba trong sáu điểm. Gần nửa giờ giấy bút, không cần máy tính bỏ túi.

Dữ liệu thật: Online Retail: 541.909 dòng giao dịch, 8 cột, của một nhà bán lẻ ở Anh trong 373 ngày (01/12/2010–09/12/2011), 4.372 mã khách. Nguồn: Chen, D. (2015), UCI, DOI 10.24432/C5BW33, CC BY 4.0. Tập KHÔNG có nhãn nào để chấm. Có 135.080 dòng thiếu mã khách, có hoá đơn huỷ, có dòng số lượng và đơn giá không dương — lớp sẽ thống nhất bốn tiêu chí lọc.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Nếu hai tâm ban đầu đặt trùng hai khách hàng, bạn đoán có ai đổi nhóm giữa chừng không?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy kẻ ô (mang nhiều) để chấm điểm và vẽ ranh giới, thêm hai màu bút để tô hai nhóm. Nửa sau cần laptop có Python với numpy, pandas, scikit-learn, hoặc Colab.

TỪ KHOÁ

học không giám sát (unsupervised learning) · phân cụm (clustering) · K-means · tâm cụm (centroid) · tổng bình phương trong cụm (WCSS) · thuật toán Lloyd (Lloyd's algorithm) · khởi tạo k-means++ (k-means++) · nghiệm cục bộ (local optimum) · quy tắc khuỷu tay (elbow method) · silhouette · chỉ số Rand hiệu chỉnh (adjusted Rand index) · gần đây · tần suất · giá trị (RFM)

BUỔI 9

Bỏ chín phần mười, giữ chín phần mười

Phân tích thành phần chính (PCA) · giảm chiều · nhận dạng hoạt động từ điện thoại

CÂU HỎI CỦA BUỔI

Có thể thay 561 toạ độ bằng một số ít toạ độ mới mà vẫn giữ được cấu trúc quan trọng không?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **TÍNH** bằng bút trung bình, ma trận hiệp phương sai, cặp trị riêng, toạ độ mới và bản dựng lại của bộ bốn điểm — ra phân số chính xác.
- ▶ **GIẢI THÍCH** vì sao hướng làm phương sai lớn nhất cũng chính là hướng làm sai số dựng lại nhỏ nhất, và ba điều kiện để điều đó còn đúng.
- ▶ **VIẾT** một quy trình không rõ ràng — chia theo người, học phép biến đổi chỉ trên tập train rồi áp lên cả hai — và nói rõ vì sao thứ tự ấy bắt buộc.
- ▶ **CHỌN** số chiều giữ lại bằng ba loại bằng chứng khác nhau, và chỉ ra vì sao ba loại ấy có thể cho ba đáp số cách nhau hàng chục lần.
- ▶ **CHỈ RA** bốn tình huống làm phương pháp này hỏng, mỗi tình huống kèm một dấu hiệu nhận biết và một con số đo được ngay trong buổi.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 8	hai câu hỏi Bài 8 để lại — hôm nay trả cả hai	Bài 8 khép lại bằng đúng hai câu hỏi chưa trả lời. Bạn nhắc lại được cả hai không?
Bài 7	rõ ràng dữ liệu và thứ tự học trên train rồi mới áp lên test	Vì sao phép chuẩn hoá phải học từ tập train rồi mới áp lên tập test?
Toán nền	nhân ma trận, tích vô hướng, chuẩn hoá độ dài vector	Vector (1, 1) dài bao nhiêu, và phải chia nó cho số nào để độ dài bằng đúng 1?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn đi trọn sáu bước của phương pháp bằng giấy bút trên đúng bốn điểm trong mặt phẳng, toạ độ đều nguyên: lấy trung bình, tâm hoá, dựng ma trận hiệp phương sai 2×2, tìm hai hướng mới, chiếu mỗi điểm xuống một con số, rồi dựng ngược lại. Gần nửa giờ giấy bút, mọi giá trị là phân số. Bốn điểm này là hiện vật dạy học được thiết kế ngược để ra số đẹp, không phải dữ liệu thật.

Dữ liệu thật: UCI HAR: 10.299 cửa sổ tín hiệu dài 2,56 giây từ gia tốc kế và con quay hồi chuyển của điện thoại đeo ở thắt lưng, 30 người tuổi 19–48, sáu hoạt động. Mỗi cửa sổ mô tả bằng 561 đặc trưng, mọi giá trị đã co về đoạn [−1, 1], không ô trống. Bộ chia sẵn THEO NGƯỜI: 21 người học, 9 người kiểm, không ai ở cả hai bên. Nguồn: Anguita và cộng sự, ESANN 2013; UCI ID 240, DOI 10.24432/C54S4K.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Giữ được chín phần mười phương sai thì có giữ được chín phần mười khả năng đoán đúng hoạt động không?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy kẻ ô (mang nhiều) để chấm điểm và vẽ hai hướng mới, thêm một bút màu thứ hai. Nửa sau cần laptop có Python với numpy và scikit-learn; tải sẵn bộ dữ liệu trước khi đến lớp.

TỪ KHOÁ

phân tích thành phần chính (principal component analysis) · giảm chiều (dimensionality reduction) · tâm hoá (centering) · ma trận hiệp phương sai (covariance matrix) · trị riêng (eigenvalue) · vector riêng (eigenvector) · thành phần chính (principal component) · toạ độ trên trục mới (score) · tỉ lệ phương sai giải thích (explained variance ratio) · sai số tái tạo (reconstruction error) · chuẩn hoá z (standardization) · phân rã giá trị suy biến (singular value decomposition)

BUỔI 10

Hơn đúng một mẫu, hay hơn năm trăm mẫu?

Mạng neuron nhiều lớp · học biểu diễn · khi nào thì đáng

CÂU HỎI CỦA BUỔI

Làm thế nào một mô hình học được biểu diễn tốt hơn thứ ta đưa cho nó?

SAU BUỔI NÀY BẠN LÀM ĐƯỢC

- ▶ **CHỨNG MINH** rằng không mô hình tuyến tính nào phân loại đúng cả bốn điểm của bài toán XOR — bằng một đẳng thức ba dòng, chỉ dùng phép cộng.
- ▶ **TÍNH** bằng bút cả sáu bước trên một mạng chín tham số: tầng ẩn, mất mát ban đầu, hiệp phương sai, gradient, một bước học — mọi số ra phân số.
- ▶ **GIẢI THÍCH** vì sao chằng thêm lớp tuyến tính không thêm được gì so với một lớp, rồi kiểm lại lời giải thích ấy bằng một phép đo trên dữ liệu thật.
- ▶ **DỰNG** một so sánh công bằng giữa hai mô hình: dò tham số trên tập validation, chia kiểm chứng chéo đúng cách, chạm tập test đúng một lần.
- ▶ **CHỈ RA** điều kiện để việc học biểu diễn đáng dùng, cùng bốn chỗ mạng neuron hỏng, mỗi chỗ kèm một số đo lấy từ chính buổi học này.
- ▶ **LIỆT KÊ** với mỗi buổi của cả học phần một niềm tin nghe rất hợp lý và con số đã bác bỏ nó.

CẦN ÔN LẠI TRƯỚC — TỰ KIỂM BA CÂU

Ôn lại từ	Nội dung	Bạn tự trả lời được không?
Bài 9	hai câu hỏi Bài 9 để lại — hôm nay trả cả hai	Bài 9 khép lại bằng đúng hai câu hỏi chưa trả lời. Bạn nhắc lại được cả hai không?
Bài 5	hồi quy logistic, sigmoid, cross-entropy — dùng lại cả ba	Hàm sigmoid bóp mọi giá trị về khoảng nào, và tại 0 nó bằng bao nhiêu?
Bài 4	một bước gradient và vai trò của tốc độ học	Viết công thức cập nhật một bước gradient. Tốc độ học quá lớn thì chuyện gì xảy ra?

Không trả lời được câu nào thì đọc lại bài đó trước khi lên lớp.

BUỔI NÀY BẠN SẼ LÀM GÌ

Tính bằng bút trên: Bạn đi trọn sáu bước của một mạng neuron bằng giấy bút trên đúng bốn điểm — bốn góc hình vuông đơn vị, nhãn chỉ 0 hoặc 1 — với mạng hai đầu vào, hai đơn vị ẩn, một đầu ra: chín tham số. Sáu tham số tầng ẩn cho sẵn, bạn chỉ học ba số của tầng cuối. Gần nửa giờ giấy bút, mọi giá trị là phân số mẫu nhỏ. Bốn điểm này là hiện vật dạy học được chọn ngược để ra số gọn, dữ liệu thật không như vậy.

Dữ liệu thật: Ba bộ thật, chạy bằng máy ở nửa sau. ①Digits: 1.797 ảnh chữ số 8×8, giá trị 0–16, 10 lớp, chia 1.257/540 — tập con của bộ UCI Optical Recognition of Handwritten Digits (Alpaydın, 1998), KHÔNG kèm mã người viết. ②MNIST: 784 pixel thô giá trị 0–255, 60.000 ảnh học và 10.000 ảnh kiểm, không có bước thiết kế đặc trưng nào của con người. ③Bộ nhận dạng hoạt động của Bài 9 quay lại làm đối chứng. Ba bộ khác nhau đúng ở một chỗ: ai đã làm việc thiết kế đặc trưng.

NGHĨ TRƯỚC — VIẾT RA GIẤY VÀ MANG THEO

Tầng cuối của mạng chỉ có ba số phải học; sau đúng một bước học, số nào thay đổi nhiều nhất?

Không có đáp án ở đây. Đoán sai cũng được — nhưng phải đoán trước khi biết.

MANG THEO

Giấy kẻ ô (mang nhiều) để kẻ bảng bốn dòng và vẽ bốn điểm. Nửa sau cần laptop có Python với numpy và scikit-learn, tải sẵn bộ dữ liệu chữ số. Cuối buổi có ba câu viết tay nộp ở cửa.

TỪ KHOÁ

mạng neuron nhiều lớp (multilayer perceptron) · tầng ẩn (hidden layer) · tầng ra (output layer) · hàm kích hoạt (activation function) · ReLU · softmax · mất mát cross-entropy (cross-entropy loss) · học biểu diễn (representation learning) · siêu tham số (hyperparameter) · kiểm chứng chéo (cross-validation)

PHỤ LỤC A — KẾT QUẢ CHÍNH CỦA MƯỜI BUỔI

Dùng để **ÔN LẠI SAU BUỔI HỌC** và làm quiz. Nếu bạn đọc phần này trước khi lên lớp thì mọi câu hỏi “hãy đoán trước” trong buổi học sẽ mất tác dụng.

Buổi 1 — “Hợp gu” là một phép tính

Kết quả 1 · điểm hợp gu cao nhất trong bảng năm phim, tính tay

$\cos(u, \text{The Fifth Element}) = 0,9707$

Kết quả 2 · bảng xếp hạng tay theo cosine, ba trục $A \cdot C \cdot S$

$P1 > P2 > P3 > P4 > P5 \text{ — } 0,9707 \cdot 0,9058 \cdot 0,7845 \cdot 0,6934 \cdot 0,5547$

Kết quả 3 · cú lật ngôi khi đổi tích vô hướng sang cosine

dot chọn P2 (8 điểm); cosine chọn P1 (0,9707), P2 tụt hạng 2

Kết quả 4 · phép kiểm tổng tích vô hướng theo hai đường độc lập

$\Sigma u \cdot v = 28$ — cộng theo phim $7+8+4+5+4$, cộng theo thể loại $16+3+9$

Kết quả 5 · cú lật ngôi thứ hai khi mở từ 3 lên 18 trục

Rush Hour lên hạng 1 (0,4544), The Fifth Element xuống hạng 2 (0,3976)

Kết quả 6 · đồng hạng hàng loạt ở quy mô thật

chỉ 61 giá trị cosine cho 3.862 phim; 839 phim cùng 0,8032; 96,7 % phim trùng vector

Buổi 2 — Đoán loài chim bằng ba người hàng xóm

Kết quả 1 · phép kiểm hai cột Δ trên sáu con chim, cộng theo hai đường độc lập

$\Sigma \Delta f = -65$ và $\Sigma \Delta m = -1900$ (tổng cột $f = 1255$; tổng cột $m = 28.100$)

Kết quả 2 · cú lật nhãn khi chỉ đổi tên đơn vị cột khối lượng, $k = 3$

vòng A (mm & g) $\rightarrow$ Chinstrap, SAI; vòng B (mm & kg) $\rightarrow$ Gentoo, đúng do may; vòng C (chia khoảng biến thiên) $\rightarrow$ Gentoo, đúng do nguyên tắc. X là Gentoo

Kết quả 3 · ba láng giềng của $k = 3$ ở vòng C sau chuẩn hoá, nhân 10.000

$1025 \cdot 2500 \cdot 3625 (G2 \cdot G1 \cdot C2)$ — cả sáu giá trị đều là số nguyên

Kết quả 4 · cùng một bảng số ở vòng A, ba giá trị k cho ba kết luận

$k = 1 \rightarrow$ Gentoo; $k = 3 \rightarrow$ Chinstrap; $k = 5 \rightarrow$ hoà 2–2–1

Kết quả 5 · bốn thí nghiệm trên 342 con, $k = 5$, kiểm chéo 5 phần phân tầng

2 đặc trưng: thô $0,7632 \pm 0,0600$ · chuẩn hoá $0,7749 \pm 0,0170$; 4 đặc trưng: thô $0,7983$ · chuẩn hoá $0,9883 (\pm 0,0059)$

Kết quả 6 · xếp hạng đòn bẫy ba can thiệp, và độ chính xác che lấp lớp thiếu số

chọn đặc trưng +21,3 điểm · chuẩn hoá +1,2 đến +19,0 điểm · dò $k + 3,9$ điểm; $k = 101$ đạt 0,7767 nhưng recall Chinstrap = 0,000; thêm 100 chiều nhiễu: $0,775 \rightarrow 0,555$

Buổi 3 — Đúng nhiều hơn, bán được ít hơn

Kết quả 1 · TP của ma trận A ra được bằng ba đường độc lập: đếm ô, qua precision, qua recall

TP = 6 — đếm ô: 6; precision $\times$ số cuộc gọi = $(6/17) \times 17 = 6$; recall $\times$ số người mua = $(3/5) \times 10 = 6$

Kết quả 2 · bốn chỉ số của hai ma trận trên bảng 100 khách (A: TP 6 · FP 11 · FN 4 · TN 79; B: TP 4 · FP 4 · FN 6 · TN 86)

A: accuracy $17/20 = 0,85$ · precision $6/17 \approx 0,3529$ · recall $3/5 = 0,60$ · F1 $4/9 \approx 0,4444$ · MCC 0,3816. B: accuracy $9/10 = 0,90$ · precision $1/2$ · recall $2/5$ · F1 $4/9$ · MCC 0,3932

Kết quả 3 · hai ma trận đối ngược, hai đường số học khác nhau, gặp nhau tại cùng một F1

$1/F1 = 9/4$ ở cả A và B $\Rightarrow F1 = 4/9$ cho cả hai; trên 12.357 khách thật: 0,4458 so với 0,4456 (hoà đến 3 chữ số)

Kết quả 4 · nghịch lý tên bài — B thắng accuracy, precision và MCC nhưng bán được ít hơn

bảng 100 ô: 6 hợp đồng so với 4. Thật trên 12.357 khách: $\tau = 3/15$ cho 839 hợp đồng / 2.372 cuộc gọi (accuracy 0,8312), $\tau = 6/15$ cho 539 hợp đồng / 1.027 cuộc gọi (accuracy 0,8915) — 300 hợp đồng đổi lấy 6,0 điểm accuracy, và không chỉ số nào nhắc tới điều đó

Kết quả 5 · mô hình một dòng return “no”, và độ ổn định giả của accuracy

baseline accuracy $0,8873 = 36.548/41.188$ với 0 hợp đồng, nhưng 10 trong 15 ngưỡng vẫn vượt được nó. 25 lần đo: accuracy $0,8961 \pm 0,0020$ (0,22 %) so với F1 $0,3548 \pm 0,0138$ (3,89 %) và recall $0,2536 \pm 0,0114$; chọn k theo accuracy ra $k = 61$, theo F1 ra $k = 5$

Kết quả 6 · đổi cách chia dữ liệu theo thời gian, và bằng ngưỡng tối ưu theo tỉ số r

chia theo thời gian: AUC 0,7719 $\rightarrow$ 0,6052 · accuracy 0,8312 $\rightarrow$ 0,6072 · F1 chỉ 0,4458 $\rightarrow$ 0,4308, vì tỉ lệ lớp dương trong tập kiểm tra tăng 11,27 % $\rightarrow$ 24,55 % và 99,60 % khách kiểm tra nằm ngoài vùng lõi suất đã học. Ngưỡng tối ưu: $r = 2 \rightarrow 8/15 \cdot r = 3 \rightarrow 6/15 \cdot r = 5 \rightarrow 4/15$ (đáp án câu hỏi 6) · $r = 8 \rightarrow 3/15 \cdot r = 12 \rightarrow 2/15 \cdot r = 20 \rightarrow 1/15$. Câu hỏi mở màn (slide 10) có đáp án D — không đủ dữ kiện cho tới khi biết r

Buổi 4 — Bước dài bao nhiêu thì tới đấy?

Kết quả 1 · nghiệm đóng trên bốn căn nhà ($x = 3, 4, 6, 7 \cdot y = 9, 8, 16, 15$) và hai phương trình chuẩn tắc

$\bar{x} = 5 \cdot \bar{y} = 12 \cdot A = 5/2 \cdot B = 5 \cdot C = 25/2 \Rightarrow J(w) = 5/2 \cdot w^2 - 10w + 25/2$; $w^* = B/A = 2$, $b^* = 2$, $\hat{y} = 2x + 2$; phần dư (+1, -2, +2, -1); $\Sigma e = 0$ và $\Sigma x \cdot e = 0$ (kiểm bằng miệng trong mười giây); $MSE = 10/4 = 5/2 = 2,50 \cdot RMSE \approx 1,58 \cdot MAE = 6/4 = 1,50 \cdot R^2 = 1 - 10/50 = 4/5 = 0,80$ (ở S38 phần lớn lớp đoán R^2 trên 0,9)

Kết quả 2 · hệ số co $r = 1 - 2\eta A$; với bài này $2A = 5$ nên $r = 1 - 5\eta$ — năm tốc độ học, năm số phận

$\eta = 0,1 \rightarrow r = 1/2$, hội tụ đơn điệu $0 \rightarrow 1 \rightarrow 3/2 \rightarrow 7/4 \rightarrow 15/8$; $\eta = 0,2 \rightarrow r = 0$, tới đấy trong MỘT bước; $\eta = 0,3 \rightarrow r = -1/2$, hội tụ nhảy qua nhảy lại $0 \rightarrow 3 \rightarrow 3/2 \rightarrow 9/4 \rightarrow 15/8$; $\eta = 0,4 \rightarrow r = -1$, dao động mãi mãi $0 \leftrightarrow 4$ mà J giữ nguyên 12,5; $\eta = 0,5 \rightarrow r = -3/2$, phân kỳ $0 \rightarrow 5 \rightarrow -5/2 \rightarrow 35/4 \rightarrow -65/8$ (sai số $\times 1,5$ mỗi bước). Hội tụ khi và chỉ khi $|r| < 1$

Kết quả 3 · bước thứ k viết thẳng ra mà không chạy k bước

$w_k - w^* = r^k (w_0 - w^*) \Rightarrow$ với $\eta = 0,1$: $w_k = 2 - 2/2^k$; $w_{10} = 2 - 1/512 = 1023/512 \approx 1,998047$ (đã kiểm bằng số học phân số chính xác; bài tập bắt buộc là tái lập đúng con số này)

Kết quả 4 · ngưỡng độ dài bước là tính chất của DỮ LIỆU, không phải của thuật toán

trên bốn căn nhà: $\eta^* = 1/A = 2/5 = 0,4$ (vượt là không bao giờ hội tụ), nhanh nhất tại $\eta = 1/(2A) = 0,2$. Tổng quát $\eta^* = 2/\lambda_{\max}$. Đổi đơn vị diện tích từ chục m^2 sang m^2 : $\lambda_{\max} \approx 5.500$, ngưỡng $\approx 0,00036$, nên $\eta = 0,01$ đang hội tụ chuyển thành PHẦN KỶ (đáp án câu hỏi S77 là B; S11 là C; S21 là C; S51 là B; S93 là B)

Kết quả 5 · Hessian, trị riêng và điều kiện số κ của bốn căn nhà — trước và sau tiền xử lý

$\Sigma x^2 = 110$, $\Sigma x = 20$, $n = 4 \Rightarrow H = [[55, 10], [10, 2]]$; vết = 57, định thức = 10, $\lambda = (57 \pm \sqrt{3209})/2 = 56,824$ và $0,1760 \Rightarrow \kappa = 322,9$ ($\eta^* = 0,0352$, zigzag: 12 bước mà hệ số chặn chưa đi được 1/4 đường). Căn giữa: $H = [[5, 0], [0, 2]]$, $\kappa = 2,50$, $\eta^* = 0,40$. Căn giữa + chuẩn hoá: $H = 2I$, $\kappa = 1,00$, $\eta^* = 1,00$ — một bước là tới

Kết quả 6 · trên 20.640 khu phố California: hai đường, hai thước đo, và dự báo phân kỳ trước khi chạy

tối thiểu MSE: $w = 41,7938 \cdot b = 45,0856 \cdot RMSE 83,7336 \cdot MAE 62,6259 \cdot R^2 = 0,4734$ ($RMSE/MAE = 1,34$). Tối thiểu MAE: $w = 43,8667 \cdot b = 20,5798 \cdot RMSE 85,4312 \cdot MAE 60,9062$ — lệch 4,96 % về độ dốc. Bỏ 965 khu bị chặn trần: độ dốc $41,79 \rightarrow 39,99$ (lệch 4,32 %). Thêm 8 cột rác với $n = 20$: $R^2 0,474 \rightarrow 0,698$ trong khi R^2 hiệu chỉnh $0,445 \rightarrow 0,427$. $\lambda_{\max} = 38,81 \cdot \lambda_{\min} = 0,372 \cdot \kappa = 104,3 \cdot \eta^* = 0,05153 \Rightarrow \eta = 0,1$ phân kỳ sau đúng 8 bước; chuẩn hoá xong $\kappa = 1$ và $\eta = 0,5$ tới đích trong một bước. Ba vòng dữ liệu: toàn phần $J = 10362$, mini-batch 256 cho $J = 7014,8 \pm 3,4$, SGD cho $J = 7117,5 \pm 94,4$ (mục tiêu 7011,3)

Buổi 5 — Mỗi giờ học thêm, cơ hội nhân đôi

Kết quả 1 · mô hình tái tạo đúng tỉ lệ đồ thô của từng nhóm trong 19 sinh viên

bốn nhóm $x = 0, 1, 2, 3$ có $n = 9, 5, 3, 2$ và mỗi nhóm ĐÚNG 1 người đồ $\Rightarrow p$ thô = $1/9 \cdot 1/5 \cdot 1/3 \cdot 1/2$. Đọc thẳng từ log-odds: $w = \ln 2 = 0,693147 \cdot b = -3 \ln 2 = -2,079442$. Tính ngược $\sigma(wx+b)$ ra lại đúng 0,111111 · 0,200000 · 0,333333 · 0,500000 — khớp tuyệt đối, không sai một chữ số

Kết quả 2 · odds nhân đôi mỗi giờ — đây là tên của buổi học (dòng bìa thứ hai)

tỉ lệ đồ cộng KHÔNG đều: hiệu số 0,0889 · 0,1333 · 0,1667. Nhưng odds = $1/8 \cdot 1/4 \cdot 1/2 \cdot 1$ nhân đều $\times 2 \cdot \times 2 \cdot \times 2$, và log-odds = $-2,0794 \cdot -1,3863 \cdot -0,6931 \cdot 0$ cách đều đúng $\ln 2 = 0,6931 \Rightarrow$ bốn điểm thẳng hàng. $e^w = 2,0000$. Ba cách nói, chỉ MỘT đúng: X 'xác suất tăng gấp đôi' · X 'xác suất tăng 100 %' · $\sqrt{\text{'odds nhân đôi'}}$ (kiểm: p đi $1/9 \rightarrow 1/5$ tỉ số 1,80; $1/3 \rightarrow 1/2$ tỉ số 1,50 — không lần nào bằng 2)

Kết quả 3 · hai phương trình điểm số — kiểm nghiệm tối ưu bằng ĐẾM, không cần máy

$\Sigma n \cdot p = 9 \cdot (1/9) + 5 \cdot (1/5) + 3 \cdot (1/3) + 2 \cdot (1/2) = 1+1+1+1 = 4 =$ số người đồ đếm bằng mắt; $\Sigma x \cdot n \cdot p = 0+1+2+3 = 6 = \Sigma x \cdot (\text{số đồ thật})$. Cả hai phần dư đúng bằng 0 $\Rightarrow$ đây CHÍNH LÀ nghiệm hợp lý cực đại. Hệ quả tổng quát: $\Sigma p = \Sigma y$ trên tập huấn luyện với mọi mô hình logistic có hệ số chặn và không chính quy hoá — dùng làm phép kiểm mã nguồn miễn phí

Kết quả 4 · ranh giới, các thước đo của bộ 19 sinh viên, và máy khớp tay tới 10^{-9}

$x^* = -b/w = 3 \ln 2 / \ln 2 = 3$ giờ chẵn ($\ln 2$ triết tiêu). Ngưỡng $\tau = 0,50$: recall 0,25 · precision 0,50; $\tau = 0,25$: recall 0,50 · precision 0,40. $L^* = 0,470386 \cdot$ mô hình rỗng $L_0 = 0,514653$ ($\bar{p} = 4/19 = 0,210526$) · cải thiện 0,044267 nat · McFadden pseudo- $R^2 = 0,0860$. scikit-learn với penalty=None cho $w = 0,6931471814$ (lệch $8,43e-10$), $b =$

-2,0794415430 (lệch 1,34e-09); xuống dốc 400 vòng lệch 9,3e-10. NHƯNG mặc định $C = 1,0$ cho $w = 0,536862 \Rightarrow e^w = 1,7106$, tức 'odds tăng 71 %' — sai hẳn kết luận

Kết quả 5 · hai thí nghiệm trả lời vì sao KHÔNG dùng MSE cho phân loại

① độ lớn gradient: log-loss cho $\partial \ell / \partial z = p - y$; MSE + sigmoid cho $2(p-y) \cdot p(1-p)$ — thừa số $p(1-p)$ không có gì để triệt tiêu. Tỉ số $= 1/[p(1-p)]$, KHÔNG phải hằng số: $p = 0,001 \rightarrow 1001,0 \cdot p = 0,1 \rightarrow 11,1 \cdot p = 0,5 \rightarrow$ đúng bằng $4 \cdot p = 0,999 \rightarrow 1001,0$. ② tính lỗi: quét lưới $w \times b = 41 \times 39 = 1.599$ điểm, đếm trị riêng âm của Hessian — log-loss 0/1599 (0 %, LỖI), MSE + sigmoid 1487/1599 (93,0 %, KHÔNG lỗi), Hessian số kiểm chéo trùng khít

Kết quả 6 · 12.357 khách hàng thật: nghịch lý AUC – log-loss, và bốn cái bẫy bằng số

mô hình rỗng AUC 0,5000 · log-loss 0,3520 · Brier 0,09996. k-NN $k=15$ của Bài 3: AUC 0,7719 · log-loss 0,8380 · Brier 0,08089. Logistic: AUC 0,7714 · log-loss 0,2834 · Brier 0,07996 — AUC chênh 0,0005 mà log-loss chênh 3,0 lần. Vì sao k-NN hỏng: chỉ 16 giá trị xác suất khả dĩ, gán ĐÚNG 0 cho 4.795 khách (38,8 %) mà trong đó 4,46 % đã đăng ký; chặn ở 10^{-6} thì log-loss 0,4530 — con số phụ thuộc quy ước là đã hỏng. Sai lệch hiệu chuẩn trung bình k-NN 0,0299, chỉ dừng được 4 ô so với 10 ô của logistic. BẦY 1 quan hệ chữ U, $n = 4.400$, p thật $0,574 \rightarrow 0,0998 \rightarrow 0,574$: w khớp $= 3,7e-07$ và AUC $= 0,5000$. BẦY 2 tách hoàn hảo ($x = 1,2,3 \rightarrow y = 0$; $x = 4,5,6 \rightarrow y = 1$): siết tol $10^{-2} \rightarrow 10^{-12}$ thì w chạy $5,14 \rightarrow 22,04 \rightarrow 44,32 \rightarrow 51,13$ và không dừng; bật L2 $C=1$ thì $w = 1,1207$ đứng yên (log-loss 0,2271). BẦY 3 ngưỡng 0,50 báo 333 ca dương / 1.392 ca thật (TP 248 · recall 0,1782 · precision 0,7447), hạ về tỉ lệ nền 0,1127 báo 3.749 (TP 998 · recall 0,7170 · precision 0,2662); ngưỡng đúng từ chi phí $p > c/v$, với $c = 20.000$ đ và $v = 1.000.000$ đ ra 0,02. BẦY 4 đổi thang đo thì nr.employed nhảy từ $|w|$ gốc 0,0068 (áp chót) lên 0,4950 theo độ lệch chuẩn (hạng nhì) vì $sd = 72,5$ so với 0,50 của previous — chênh 145 lần. Đáp án trắc nghiệm: cắt cụt $\rightarrow C \cdot$ pseudo- $R^2 = 0,086 \rightarrow C \cdot$ hệ số lớn nhất $\rightarrow C$

Buổi 6 — Hồi ít câu hơn, đoán đúng hơn

Kết quả 1 · Gini của nút gốc trên 16 hạt, và cùng một biểu thức đã gặp ở Bài 5

$G(\text{gốc}) = 1 - (8/16)^2 - (8/16)^2 = 1/2$ — giá trị TỆ NHẤT có thể với hai lớp. Kiểm bằng đường thứ hai: với 2 lớp $G = 2p(1-p)$, $p = 1/2 \Rightarrow G = 1/2 \checkmark$. Chính thừa số $p(1-p)$ của Bài 5: ở đó nó bóp gradient của MSE + sigmoid (chênh tới 1001 lần), ở đây nó là thước đo mà ta MUỐN cho nhỏ. Ba phân số dùng suốt phần tính tay: $G = 1/2$ (16 hạt, 8S/8H) · $G = 8/25 = 0,32$ (10 hạt, 8S/2H) · $G = 0$ (6 hạt, 0S/6H). Nút bẫy lớp đều: $G = 1 - 7 \cdot (1/7)^2 = 6/7 \approx 0,857$

Kết quả 2 · độ tròn thẳng chiều dài đúng 2,4 lần — cả lớp đã đoán sai ở đầu buổi

Nhất cắt tốt nhất theo chiều dài $L \leq 303,5$ chia 8–8 (6S/2H và 2S/6H), G hai con đều 3/8, $W = 3/8 \Rightarrow \Delta_L = 1/2 - 3/8 = 1/8$. Nhất cắt tốt nhất theo độ tròn $R \leq 0,855$ chia 6–10, con trái 0S/6H THUẦN ($G = 0$), con phải 8S/2H ($G = 8/25$), $W = 1/5 \Rightarrow \Delta_R = 1/2 - 1/5 = 3/10$. Tỉ số $(3/10)/(1/8) = 24/10 = 2,4$. Lý do: theo chiều dài hai giống chồng lấn từ 256 tới 358 (6 hạt SEKER và 4 hạt HOROZ cùng khoảng), còn theo độ tròn 6 hạt HOROZ nằm trong khoảng 0,66–0,84 và không hạt SEKER nào xuống dưới 0,87. Đối chứng bỏ trọng số: nhất cắt $L \leq 223,5$ tách đúng 1 hạt cho $G_T + G_P = 0,498 < 0,320$ nên sẽ 'thắng' — tiêu chí sai chọn ra cây vô dụng mà không có thông báo lỗi. Đổi Gini sang entropy: cùng đặc trưng thẳng, cùng ngưỡng 0,855; chỉ ngưỡng THUA của L đổi từ 303,5 sang 248,5

Kết quả 3 · luật bảo toàn khớp sai số đúng bằng 0, và feature importance rơi thẳng ra

Nhất cắt thứ hai trên 10 hạt còn lại: $L \leq 374,5$ tách thuần cả hai bên (8 SEKER · 2 HOROZ là $H7 = 391$ và $H8 = 408$ — hai hạt 'tròn bất thường' cũng chính là hai hạt dài nhất). Δ cục bộ $= 8/25 = 0,32$, LỚN hơn 0,30 của nhất cắt một, nhưng tính trên tập khác: quy về toàn cục $0,32 \times 10/16 = 1/5 = 0,20 < 0,30$. Luật bảo toàn: $3/10 + (10/16) \cdot (8/25) = 3/10 + 1/5 = 1/2 = G(\text{gốc})$, sai số ĐÚNG bằng 0, không phải xấp xỉ (tổng telescoping, đúng khi mọi lá đều thuần). Chia cho tổng $1/2$: độ tròn 3/5 = 60 %, chiều dài 2/5 = 40 %, cộng đúng 100 %. Cây cuối: sâu 2 · 3 lá · đúng 16/16. scikit-learn trên đúng bộ số này trả về 3 lá, sâu 2, nhất cắt gốc cột 1 $\leq 0,855$, accuracy 1,0 và feature_importances_ = [0,4 ; 0,6] — khớp tuyệt đối

Kết quả 4 · 13.611 hạt thật: cắt bỏ 653 lá thì train GIẢM còn test TĂNG — đây là tên của buổi học

Bốn mốc trên 2.723 hạt kiểm tra: đoán bừa (luôn nói DERMASON) 0,2604 · một câu hỏi duy nhất (MajorAxisLength $\leq 281,14$) 0,4047 · cây đã cắt tia 0,9082 · rừng 300 cây 0,9218. Cây mọc tự do: 698 lá · sâu 29 · 697 nút trong · train 1,000000 · test 0,891664 · khoảng cách 0,108336. Cây cắt tia với $ccp_alpha = 6,516712e-04$ chọn theo định CV: 45 lá · sâu 9 · train 0,928821 (-0,0712) · test 0,908189 (+0,0165) — 653 lá bị cắt, số câu hỏi tối đa từ 29 xuống 9. Quét độ sâu: sâu 1 train 0,4075 / test 0,4047; sâu 5 train 0,8934 / test 0,8810; sâu 8 train 0,9394 / test 0,9034; sâu 20 train 0,9972 / test 0,8953. Định CV ở độ sâu 8, định test ở độ sâu 10 (0,9056 so với 0,9034, chênh 0,0022 — nhỏ hơn độ lệch chuẩn CV 0,005): vẫn phải theo CV, nếu không thì rồi rí tập kiểm tra

Kết quả 5 · cây bất biến với đổi thang đo — 2.723 dự đoán trùng khít TỪNG BIT

Nhân riêng cột Area với 1.000 rồi chia cho 1.000: cây giữ nguyên accuracy 0,908189 cả ba lần và mã băm của toàn bộ 2.723 dự đoán đều là f889998a0bf2 — biên độ 0,000000. Đối chứng dương k-NN thô: 0,724201 · 0,590525 · 0,803526, biên độ 0,2130 tức 21,3 điểm phần trăm; k-NN đã chuẩn hoá đứng yên ở 0,916636. Lý do k-NN vờ: trên dữ liệu thô, ConvexArea chiếm 50,7542 % và Area 49,2424 % tỉ trọng phương sai trong khoảng cách Euclid (hai cột =

99,997 %), Perimeter 0,0026 %, mười ba cột còn lại cộng lại 0,0007 %. Phát biểu đúng phải đủ bốn chữ 'đơn điệu từng cột': cây ĐÔI khi quay trục hoặc dùng PCA

Kết quả 6 · rừng ngẫu nhiên, và bốn bẫy — mỗi bẫy một thí nghiệm đã chạy

Rừng: bootstrap giữ trung bình 63,2 % số hàng ($1 - e^{-1}$), mỗi nút chỉ nhìn $\sqrt{16} = 4$ cột; 1 cây 0,8946 → 50 cây 0,9214 → 300 cây 0,9218 (bảo hoà sau 50 cây; phương sai của trung bình có sản phẩm). Macro-F1 0,9209 → 0,9342, thắng ở cả bảy giống nhưng chỉ thêm 37 hạt đúng trên 2.723, đổi lại mất hẳn khả năng giải trình (300 cây, trung bình 591 lá, sâu trung bình 24,1). Ô lỗi CALI ↔ BARBUNYA 34 → 26 lỗi (-24 %); SIRA ↔ DERMASON 114 → 102 (-11 %, hai giống thật sự chồng lấn). F1 theo giống, cây → rừng: BOMBAY 1,0000 → 1,0000 · SIRA 0,8393 → 0,8590 (thấp nhất) · BARBUNYA 0,8922 → 0,9189. Khẳng định 'BOMBAY sạch vì kích thước' đã bị BẮT LÀ SAI: Area nhỏ nhất của BOMBAY là 114.004 còn lớn nhất của giống khác là 116.272 — chồng lấn 4 hạt. BẦY 1 XOR bốn điểm: MỌI nhát cắt có $\Delta = 0$ đúng bằng 0, cây sâu 1 và hồi quy logistic đều 0,50, cây sâu 2 được 1,00 — đây là món nợ Bài 5 trả bằng số. BẦY 2: rừng 300 cây CÙNG có train 1,000000 mà test 0,921777 (khoảng cách 0,0782) trong khi cây tự do train 1,000000 test 0,891664 — giá trị train không phân biệt được, khoảng cách thì có. BẦY 3: 12 lần bootstrap cho số lá 53–65, ngưỡng gốc 276,4–747,0, có lần cột gốc đổi hẳn sang Perimeter, nhưng accuracy chỉ dao động 0,8968–0,9104 (độ lệch chuẩn 0,0043) — ổn định về dự báo, KHÔNG ổn định về cấu trúc. BẦY 4: MDI xếp MajorAxisLength hạng nhất (0,2019) còn hoán vị trên tập kiểm tra xếp Perimeter hạng nhất (0,2158); 4 đặc trưng có MDI đúng bằng 0 (Area, AspectRatio, Eccentricity, Extent) mà không hề vô dụng. Đáp án ba câu trắc nghiệm: 'chia đôi cho cân bằng' → C · '0,32 > 0,30 nên chiều dài quan trọng hơn' → C · 'cây dễ giải thích nên kết luận đáng tin' → C

Buổi 7 — Đúng một trăm phần trăm, sai từ đầu

Kết quả 1 · bảng chéo CHÉO HOÁ: cột trạng thái xác định nhãn chứ không dự báo nhãn

Hiện vật 12 dòng, đếm bốn ô: (Check-Out, y=0) = 6 · (Check-Out, y=1) = 0 · (Canceled, y=0) = 0 · (Canceled, y=1) = 6 — hai ô ngoài đường chéo đều bằng 0, quan hệ là HÀM SỐ chứ không phải thống kê. Quy tắc R1 'reservation_status = Canceled thì huỷ' đúng 12/12 = 1. Trên dữ liệu thật, bảng chéo ba mức: Canceled 0 / 43.017 · Check-Out 75.166 / 0 · No-Show 0 / 1.207 — ba ô lẽ ra phải có số đều bằng 0; quy tắc một dòng y = 0 nếu status == 'Check-Out' đúng 119.390 / 119.390 hàng, nên đúng trên mọi tập con kể cả test. Đưa đủ 31 cột vào: hồi quy logistic VÀ rừng ngẫu nhiên đều cho accuracy = F1 = AUC = precision = recall = 1,000000 trên 23.878 đặt phòng test; ma trận nhầm lẫn 15.033 đúng không huỷ · 8.845 đúng huỷ · báo nhầm 0 · bỏ sót 0. Hai họ mô hình khác hẳn nhau cùng ra điểm hoàn hảo ⇒ vấn đề nằm ở dữ liệu, không ở mô hình. Một quyết định gán nhãn ẩn trong bảng: No-Show (1.207 hàng) được gán is_canceled = 1

Kết quả 2 · rò rỉ hiển nhiên đáng đúng MỘT PHẦN TƯ trên hiện vật, 0,117430 trên dữ liệu thật

Ba quy tắc một cột trên 12 đặt phòng: R1 cột trạng thái (rò rỉ) 12/12 = 1 · R2 'có cọc ⇒ huỷ' 9/12 = 3/4 (nhóm có cọc 4 đúng / 1 sai, nhóm không cọc 5 đúng / 2 sai; cột này KHÔNG chéo hoá) · R3 ngưỡng lead_time tốt nhất 8/12 = 2/3 · đoán bữa 6/12 = 1/2. Khoảng cách 1 - 3/4 = 1/4. Chi tiết phải nói đúng: 11 ngưỡng trung điểm cho 7 hoặc 8 dòng đúng, và có tới NĂM ngưỡng cùng đạt 8/12 (27,5 · 53,5 · 86,5 · 132,5 · 172,5) — ngưỡng tối ưu KHÔNG duy nhất, khác Bài 6 nơi nhát cắt tối ưu là duy nhất (khác biệt do cỡ hiện vật). Dữ liệu thật: bỏ hai cột rò rỉ thì rừng 1,000000 → 0,882570, logistic → 0,818662; mốc 1 = 0,117430. Hiện vật phóng đại khoảng 2,1 lần (1/4 = 0,2500 so với 0,117430)

Kết quả 3 · tỉ lệ huỷ NHÂN ĐÔI giữa hai nửa thời gian: 1/3 → 2/3, và chia ngẫu nhiên giấu mất

Hiện vật xếp theo ngày đến: nửa đầu T1–T6 có 2/6 = 1/3 huỷ (T3, T5); nửa sau T7–T12 có 4/6 = 2/3 huỷ (T8, T10, T11, T12). Kiểm chéo miễn phí: (1/3 + 2/3)/2 = 1/2 = tỉ lệ chung — không khớp thì đã đếm sai. Chia ngẫu nhiên cho cả hai bên ≈ 1/2, che tròn chênh lệch 1/3 (mốc 2 trên hiện vật). Dữ liệu thật, ranh giới 22/04/2017: train 01/07/2015 → 22/04/2017 có 95.512 hàng, tỉ lệ huỷ 0,360876; test 22/04/2017 → 31/08/2017 có 23.878 hàng, tỉ lệ huỷ 0,408577 (cao hơn 0,0477). Mức dịch chuyển: hiện vật 2,00× so với 1,13× thật — phóng đại 1,8 lần. Chia đúng cách: rừng 0,882570 → 0,783357 (mốc 2 = 0,099213), logistic 0,818662 → 0,773557 (chỉ tụt 0,0451 — bằng 0,45 lần). Hình dạng sai lầm đôi: recall 0,7686 → 0,5845 (-0,1841) trong khi precision 0,8998 → 0,8359; mô hình gộp phân phối lạ thì BỎ SÓT nhiều hơn, và với khách sạn bỏ sót đắt hơn báo nhầm. Cảnh báo trung thực: mức tụt 0,099213 gồm hai thành phần — ảo tưởng bị bóc đi và bài toán thật sự khó hơn — và bài giảng KHÔNG tách được chúng

Kết quả 4 · cột NGÀY kín đáo: bảng chéo tuyên vô tội, chỉ câu ① bắt được — 0,035263

Bảng kiểm diện tròn cho bốn cột: lead_time và deposit_type GIỮ (①✓, ②③④⑤ đều 'không'); reservation_status LOẠI (①X, cả ②③④⑤ đều CÓ); reservation_status_date LOẠI (①X, ②④⑤ CÓ nhưng ③ nói 'không' — đây là ô quan trọng nhất cả bảng). Dữ liệu thật: bỏ reservation_status mà GIỮ cột ngày → 0,917832 (chỗ đa số người phân tích dừng lại và yên tâm); bỏ CẢ HAI → 0,882570; chênh +0,035263 (mốc 3). Vì sao ③ bỏ sót: phép kiểm suy biến theo số MỨC — reservation_status 3 mức, 100 % dữ liệu nằm ở ô thuận một nhãn; reservation_status_date 926 mức, chỉ 3,20 % dữ liệu nằm ở ô thuận (145 ngày thuận chứa 3.822 hàng, trung vị 6 hàng/ngày), 781/926 ngày lẫn cả hai nhãn. Cơ chế rò rỉ nằm ở ĐẦU của hiệu (ngày trạng thái - ngày đến): ghi TRƯỚC ngày đến 42.137 hàng, tỉ lệ huỷ 1,000000 · ghi TRỪNG ngày đến 2.793 hàng, 0,747225 · ghi SAU 74.460 hàng, 0,000000 ⇒ một câu IF ba nhánh đạt

0,994087 mà không huấn luyện gì, cao hơn hẳn 0,917832 mà rừng khai thác được (rừng phải xấp xỉ mặt phẳng nghiêng bằng hàng trăm bậc thang). Ba ngày bất thường: 2015-01-01 có 763 hàng toàn huỷ (gấp 125 lần trung vị) · 2014-10-17 có 180 hàng toàn huỷ và năm TRƯỚC kỳ dữ liệu · 2015-08-16 có 152 hàng toàn không huỷ. Cùng cấu trúc với cột duration của Bank Marketing đã loại ở Bài 3

Kết quả 5 · 31,46 % tập test là bản sao nguyên vẹn của một hàng train — rừng hưởng lợi gấp 1,65 lần

$31.994 / 119.390 = 26,80\%$ số hàng là bản sao (giữ bản đầu, đếm phần còn lại); còn 87.396 hàng duy nhất; $87.396 + 31.994 = 119.390$ ✓. Trong lần chia ngẫu nhiên: $7.513 / 23.878 = 31,46\%$ hàng test là bản sao NGUYÊN VẸN của một hàng train — cùng 32 giá trị, cùng nhãn — nên định nghĩa 'chưa từng thấy' bị vi phạm theo nghĩa đen. Bỏ trùng rồi đánh giá lại: rừng 0,882570 → 0,843078 (mất 0,039492), logistic 0,818662 → 0,794737 (mất 0,023925); tỉ số 1,65 lần, khớp với cơ chế ghi nhớ (Bài 6: rừng đạt train 1,000000). Bẫy đọc bảng: sau khi bỏ trùng, tỉ lệ huỷ đổi 0,3704 → 0,2749 và mốc đoán bừa đổi 0,629575 → 0,725114, nên hai cột accuracy KHÔNG so sánh trực tiếp được. Giả định chưa kiểm chứng được: hàng trùng có thể là lỗi nhân bản, cũng có thể là các đơn thật giống hệt nhau — tập không có mã đặt phòng để phân biệt

Kết quả 6 · thang bậc đầy đủ: bẫy sách vở nhắc nhiều nhất đứng CUỐI bảng, mang dấu âm

Đo trên cùng 23.878 đặt phòng test: ① cột rõ ràng hiển nhiên reservation_status +0,117430 (sách vở nhắc rất nhiều) · ② chia ngẫu nhiên trên dữ liệu có trục thời gian +0,099213 (nhắc ít) · ③ không bỏ hàng trùng lặp +0,039492 (nhắc rất ít) · ④ cột anh em reservation_status_date +0,035263 (hầu như không nhắc) · ⑤ fit StandardScaler trên toàn bộ dữ liệu -0,0000418796 (nhắc nhiều nhất): 0,7384203032 khi làm sai so với 0,7384621828 khi làm đúng, tức ≈ 1 hàng trên 23.878 — là NHIỀU, không phải hiệu ứng. Kết luận ĐƯỢC rút: nguyên tắc 'chia trước, học sau' vẫn bắt buộc vì nó bảo vệ khỏi mã hoá mục tiêu và chọn đặc trưng theo nhãn (rõ ràng rất mạnh) và vì tuân thủ nó miễn phí nhờ Pipeline; điều phải sửa là THỨ TỰ CHÚ Ý. Trả món nợ 6b: ưu thế rừng trừ logistic = 0,0639 khi chia ngẫu nhiên, còn 0,0098 khi chia theo thời gian — co đúng 6,52 lần, vẫn dương nhưng phần lớn là hiện vật của giao thức đánh giá. Hai lỗi im lặng người soạn tự mắc và tự bắt: groupby bỏ NaN cho 136 nhóm so với 62.762 nhóm khi dropna=False (chênh 461 lần), và phát biểu quá mạnh 'bảng chéo hoàn toàn bỏ sót' bị số đo bác bỏ (781/926, không phải 100 %). Đếm thật GridSearchCV: $4 \times 3 \times 5 + 1 = 61$ lần gọi .fit, đếm ra đúng 61. One-hot: 29 cột → 257 cột (gấp 8,86 lần), country 177 mức, 81 mức hiếm chỉ mang 250 hàng = 0,209 %. Quy sai số ra tiền theo GIÁ ĐỊNH 95 € × 3 đêm = 285 €/đơn và hệ số 2× cho báo nhầm (hệ số do người soạn đặt ra, không có nguồn): không mô hình 2.520.825 € · có mô hình 1.014.885 € · tiết kiệm 1.505.940 €. Đáp án ba câu trắc nghiệm: 'sếp báo accuracy 0,99' → C · 'giữ cột trạng thái, chỉ dừng dừng lúc dự báo' → B · 'nhận notebook accuracy 0,94, kiểm ba thứ nào trước' → B. Món nợ để lại buổi sau: 7a — sau khi đo đúng thì cải thiện có hệ thống thế nào; 7b — nếu chính nhãn cũng sai (No-Show gán = 1) thì mọi con số hôm nay nghĩa là gì

Buổi 8 — Máy chọn hai, người chọn bốn

Kết quả 1 · J KHÔNG BAO GIỜ TĂNG — sáu nửa bước, và một phép nhân kiểm được cả dây chuyền

Hiện vật 6 khách hàng An (1,1) · Bình (2,1) · Chi (3,3) · Dung (5,4) · Hà (6,5) · Lan (7,5), K = 2, tâm ban đầu trùng An và Chi. Dây sáu nửa bước: 39 (gán) → 12 (cập nhật) → $93/8 = 11,625$ (gán) → $22/3 \approx 7,333$ (cập nhật) → $22/3$ (gán) → $22/3$ (cập nhật, đã hội tụ sau đúng 2 vòng). Ba nửa bước đầu giảm nghiêm ngặt, ba nửa bước cuối giữ nguyên. Chi tiết: vòng 1 phân hoạch {An, Bình} | {Chi, Dung, Hà, Lan}, J = $0+1+0+5+13+20 = 39$; hai tâm mới (3/2, 1) và (21/4, 17/4), dịch 0,5 và 2,25 đơn vị, J tụt 39 → 12 mà KHÔNG ai đổi nhóm — bằng chứng cho lập luận hai nửa bước, mỗi nửa tối ưu một biến. Tâm cuối (2, 5/3) và (6, 14/3); J cuối = $14/3 + 8/3 = 22/3$. Bất biến 2 (tổng phần bằng tổng) và bất biến 3 trên dữ liệu thật: $J(K=1) = n \times d = 4.338 \times 3 = 13.014$, đo được 13.014,0 — khớp đến từng chữ số. MỐC 1 đã diễn ở cả hai cột

Kết quả 2 · Chi đổi cụm vì biên độ 3/8 — và một phần ba khách thật cũng nằm ở biên

Vòng 2: Chi cách tâm 1 là $25/4 = 6,250$, cách tâm 2 là $53/8 = 6,625$; chênh đúng $3/8 = 0,375$, bằng 0,96 % của J vòng 1. Đa số lớp đoán Chi ở lại cụm 2 vì Chi từng LÀ tâm của cụm ấy. Báo cáo phân khúc chỉ ghi 'Chi → Nhóm 1', không dấu vết nào của con số 0,375. Trên 4.338 khách thật với K = 4 (silhouette trung bình 0,3355): 1.442 khách = 33,24 % có $s < 0,25$ — ngưỡng 0,25 là quy ước người soạn đặt ra để đếm, không có nguồn, nên con số 33,24 % phụ thuộc ngưỡng ấy; điều KHÔNG phụ thuộc ngưỡng: 79 khách = 1,82 % có silhouette ÂM, tức theo chính thước đo ấy họ bị gán sai cụm. Đề xuất thực hành: lưu thêm khoảng cách tới tâm gần nhất và gần nhì, đánh dấu khách ở biên

Kết quả 3 · cùng dữ liệu, cùng K: 6 điểm cho 4 lòng chảo (+78,95 %), 4.338 khách cho +0,0427 %

K = 2 trên hiện vật: thử mọi cặp tâm trên lưới nửa nguyên trong $[0,8]^2$ — 41.616 cặp, loại 9.506 cặp vì có cụm rỗng, còn 32.110 khởi tạo hợp lệ, TẤT CẢ về cùng một nghiệm J = 22/3; vét cạn 31 phân hoạch của 6 điểm thành 2 nhóm xác nhận đó là tối ưu toàn cục — chỉ một lòng chảo. K = 3: đủ 20 bộ ba điểm cho BỐN nghiệm — $19/6 \approx 3,1667$ {An,Bình} {Chi} {Dung,Hà,Lan} 8/20 lần, tối ưu toàn cục · $7/2 = 3,5$ (4/20, tệ hơn 10,5 %) · $31/6 \approx 5,1667$ (4/20, tệ hơn 63,2 %) · $17/3 \approx 5,6667$ (4/20, tệ hơn 34/19 lần = +78,95 %). Cả bốn đều hội tụ hợp lệ, không cái nào là lỗi lập trình. Dữ liệu thật, K = 4, 200 lần chạy k-means++ với n_init = 1, hạt giống 0...199: chỉ 11,0 % chạm nghiệm tốt nhất; J tốt nhất 3.924,4 · tệ nhất 3.926,1, chênh 0,0427 % — cùng hiện tượng, độ lớn chênh gần hai nghìn lần, nên

phải ĐO chứ không suy. Nhưng J gần bằng nhau KHÔNG có nghĩa phân hoạch giống nhau: ARI trên 190 cặp có giá trị thấp nhất 0,860, trung bình 0,948; tăng n_{init} lên 20 chỉ nâng lên thấp nhất 0,9149 và trung bình 0,9601, độ tán mạn inertia 0,0283 % $\rightarrow$ 0,0101 % — vẫn KHÔNG về 1. Kết luận: 'giữ lần chạy có inertia nhỏ nhất' chưa phải một quy trình đủ; mập mờ nằm ở DỮ LIỆU

Kết quả 4 · J giảm nghiêm ngặt theo K và chạm 0 — đường cong thật KHÔNG có khuỷu

Vết cạn mọi phân hoạch của 6 điểm cho từng K (số phân hoạch = Stirling loại hai: 1, 31, 90, 65, 15, 1): J tối ưu = $269/6 \rightarrow 22/3 \rightarrow 19/6 \rightarrow 1 \rightarrow 1/2 \rightarrow 0$. Tại $K = n$ mỗi điểm là tâm của chính nó $\Rightarrow J = 0$, nên chọn theo J là chọn mỗi khách một cụm. Đây là định lý nhỏ, không phải quan sát may rủi. Dữ liệu thật, quét $K = 2 \dots 8$: inertia $6.474 \rightarrow 4.856 \rightarrow 3.924 \rightarrow 3.268 \rightarrow 2.840 \rightarrow 2.533 \rightarrow 2.326$; mức giảm tương đối 24,99 % · 19,19 % · 16,72 % · 13,10 % · 10,81 % · 8,19 % — bước gãy lớn nhất chỉ 5,80 điểm phần trăm, đường cong xuống ĐỀU, elbow cho một cuộc tranh luận chứ không cho câu trả lời. Quy về phần trăm phương sai giải thích được (chia cho $J(K=1) = 13.014$): $K=2 \rightarrow 50,25\%$ · $K=4 \rightarrow 69,84\%$ · $K=8 \rightarrow 82,13\%$; đại lượng này không có đơn vị, cùng dạng với R^2 của Bài 4. MỐC 3 đã điền ở cả hai cột

Kết quả 5 · MỐC 4 · điểm hình học CAO NHẤT cả bài thuộc về cách chia VÔ DỤNG nhất

Phương sai thô ba trục trên 4.338 khách: $R \ 10.000,1 \ (0,0124\%)$ · $F \ 59,2 \ (0,0000733\%)$ · $M \ 80.787.636 \ (99,9875\%)$; tỉ số $M/F \approx 1,36$ triệu lần, nên khoảng cách Euclid trên dữ liệu thô thực chất CHỈ đo Monetary. Sau $\log_{1p}$ + chuẩn hoá: mỗi trục 33,33 %. Độ lệch trước $\rightarrow$ sau $\log_{1p}$: $R \ 1,246 \rightarrow -0,327$ · $F \ 12,067 \rightarrow 1,209$ (giảm 10 lần nhưng VẪN lệch, vì F là biến đếm dồn ở biên) · $M \ 19,325 \rightarrow 0,394$. Bỏ bước chuẩn hoá, cùng $K = 2$, cùng dữ liệu: silhouette = 0,984489 cho cách chia $4.330 / 8$ — cao gấp 2,276 lần giá trị 0,432624 của bản đã chuẩn hoá (chia $2.669 / 1.669$). Bảng thô còn tệ hơn ở K lớn: $K=3 \rightarrow 0,9590 \ (4.303 \cdot 5 \cdot 30)$, $K=4 \rightarrow 0,9543 \ (4.300 \cdot 2 \cdot 31 \cdot 5)$. Quy tắc rút ra: không bao giờ đọc silhouette mà không đọc kèm kích thước cụm — chỉ cần thêm một cột kích thước là ba dòng điểm cao nhất tự loại. Quét silhouette bản chuẩn hoá: $K=2 \ 0,432624$ (cực đại) · $K=3 \ 0,337749$ · $K=4 \ 0,335547$ · $K=5 \ 0,318192$ · $K=6 \ 0,315561$ · $K=7 \ 0,310149$ · $K=8 \ 0,301952$; $K=2$ hơn $K=4$ tới 0,097077, còn $K=3$ và $K=4$ gần như hoà (chênh 0,002201)

Kết quả 6 · tên bài thành số: máy chọn K = 2, người chọn K = 4 — và nói rõ mình hy sinh cái gì

Quyết định chọn $K = 4$: tách được 'khách mới' khỏi 'khách đều đặn' (hai chiến dịch khác hẳn) · cụm nhỏ nhất còn 720 khách, đủ lớn để làm chiến dịch · giải thích 69,8 % phương sai · nằm trong khoảng 3–5 nhóm phòng marketing yêu cầu. Cái hy sinh: silhouette 0,335547 thay vì 0,432624. Bốn hồ sơ cụm (trung vị, thang gốc): gộp bỏ 720 khách (16,6 %) $R=9$ · $F=10$ · $M=\pounds 3.726,08 \rightarrow 64,94\%$ doanh thu | mới 877 khách (20,2 %) $R=19$ · $F=2$ · $M=\pounds 450,84 \rightarrow 5,19\%$ | đều đặn 1.162 khách (26,8 %) $R=54$ · $F=4$ · $M=\pounds 1.353,74 \rightarrow 23,64\%$ | nguội 1.579 khách (36,4 %) $R=183$ · $F=1$ · $M \approx \pounds 300 \rightarrow 6,24\%$. Con số cho ban giám đốc: 16,60 % khách nắm 64,94 % doanh thu, chênh 3,91 lần. Làm sạch: 541.909 dòng – 9.288 hoá đơn huỷ – 135.080 thiếu mã khách – 10.624 $Quantity \leq 0$ – 2.517 $UnitPrice \leq 0 \rightarrow 397.884$ dòng (73,42 %) · 18.532 hoá đơn · 4.338 khách; bốn tiêu chí CHỒNG nhau (132.260 dòng dính 1 · 10.046 dính 2 · 1.719 dính 3 · 0 dính cả 4) nên cộng thẳng là báo cáo sai. Đếm đúng: 397.884 dòng / 18.532 hoá đơn = 21,5 dòng mỗi đơn, ai đếm số dòng thay số hoá đơn thì F sai gấp hai mươi lần mà không có thông báo lỗi. Đáp án ba câu trắc nghiệm: 'cứ chọn K có điểm cao nhất' $\rightarrow C$ · 'Chỉ đổi nhóm vì 3/8' $\rightarrow C$ · 'đồng nghiệp gửi silhouette 0,91, hỏi ba câu nào trước' $\rightarrow B$. Hai lỗi người soạn tự mắc và tự bắt: Recency trừ trên đầu thời gian thay vì `.dt.normalize()` làm lệch đúng 1 ngày cho 4.338/4.338 khách, sau $\log_{1p}$ mức lệch chênh 260 lần giữa khách mới nhất và cũ nhất, kích thước bốn cụm đổi $713 \cdot 810 \cdot 1193 \cdot 1622 \rightarrow 720 \cdot 877 \cdot 1162 \cdot 1579$; và độ lệch của F 12,062859 (ddof=1) so với 12,067031 của pandas — lệch ở chữ số thứ tư là do ĐỊNH NGHĨA bậc tự do, không phải sai số làm tròn. Trang mô tả UCI ghi 'Has Missing Values? No' trong khi tệp thiếu 135.080 mã khách — lần thứ hai trong khoả tài liệu không khớp tệp. Món nợ để lại: 8a — dữ liệu Bài 9 có 561 chiều, không vẽ được, dựa vào đầu để tin kết quả; 8b — ai thiết kế biểu diễn khi không ai đặt nổi ba con số bằng tay, và đó là PCA

Buổi 9 — Bỏ chín phần mười, giữ chín phần mười

Kết quả 1 · ma trận hiệp phương sai của bộ 4 điểm, và hai đại lượng bảo toàn để kiểm nó

Hiện vật: $A(3, 4)$ · $B(4, 3)$ · $C(6, 7)$ · $D(7, 6)$. Trung bình mu = (5, 5) — số nguyên, nên bước tâm hoá không sinh phân số. Sau tâm hoá: $A'(-2, -1)$ · $B'(-1, -2)$ · $C'(1, 2)$ · $D'(2, 1)$, tổng mỗi cột bằng đúng 0 (phép kiểm miễn phí thứ nhất, bắt được lỗi số học, tính sai mu, nhầm dấu, tâm hoá sai chiều). Bốn tích ngoài $x'x'^T$ lần lượt là $[[4,2],[2,1]]$, $[[1,2],[2,4]]$, $[[1,2],[2,4]]$, $[[4,2],[2,1]]$; tổng = $[[10,8],[8,10]]$; chia cho $n = 4$ cho $C = [[5/2, 2], [2, 5/2]]$. Hai đại lượng bảo toàn: $\text{trace}(C) = 5$ và $\det(C) = 25/4 - 4 = 9/4$. Tương quan giữa hai cột = 0,8 $\Rightarrow$ đám mây nghiêng lên mạnh. Năm ràng buộc thiết kế ngược của hiện vật: mu nguyên · C hữu tỉ đơn giản · eigenvector ở đúng 45 độ · EVR chẵn 90/10 · A và B trùng toạ độ mới trên trục thứ nhất. Quy ước $1/n$ dùng xuyên suốt; nếu dùng $1/(n-1)$ thì mọi trị riêng nhân cùng hằng số $n/(n-1)$, eigenvector và EVR không đổi, nhưng đẳng thức ở Kết quả 4 không còn đúng nguyên dạng.

Kết quả 2 · cặp trị riêng 9/2 và 1/2 — kiểm khớp cả trace lẫn định thức

$C \cdot (1,1) = (9/2, 9/2) = (9/2) \cdot (1,1) \Rightarrow \lambda_1 = 9/2$, $w_1 = (1,1)/\sqrt{2}$, hướng 45 độ. $C \cdot (1,-1) = (1/2) \cdot (1,-1) \Rightarrow \lambda_2 = 1/2$, $w_2 = (1,-1)/\sqrt{2}$, hướng 135 độ. Phép kiểm 2: $9/2 + 1/2 = 5 = \text{trace}(C)$ ✓. Phép kiểm 3: $(9/2) \cdot (1/2)$

$= 9/4 = \det(C) \checkmark$. $EVR_1 = (9/2)/5 = 9/10 = 90\%$ và $EVR_2 = 1/10 = 10\%$. Độ dài trực tỉ lệ với căn của trị riêng: $\sqrt{4,5} \approx 2,121$ và $\sqrt{0,5} \approx 0,707$ — phương sai gấp 9 lần nhưng độ dài chỉ gấp 3 lần, đừng lẫn hai tỉ số. Nếu không khoá độ dài $w = 1$ thì $w^T C w$ phóng đại tùy ý: cùng hướng 45 độ, $(1,1)/\sqrt{2}$ cho $4,5 \cdot (1,1)$ cho $9 \cdot 10 \cdot (1,1)/\sqrt{2}$ cho 450. Cảnh báo cài đặt: `np.linalg.eigh` trả về trị riêng TĂNG dần, thiếu dòng `argsort` thì 'PC1' của bạn là hướng phương sai nhỏ nhất và EVR_1 ra 10 % thay vì 90 %. Dấu của eigenvector vô định về toán (`eigh` trả $w_2 = (-1,1)/\sqrt{2}$, vẫn đúng) nên đừng bao giờ `assert` dấu cứng; `sklearn` thì CÓ quy ước `svd_flip` và trên UCI HAR nó đúng với cả 5 thành phần đầu (PC1 cột 281 loading 0,05857 · PC2 cột 296 loading 0,12239 · PC3 cột 57 loading 0,11006, đều mang dấu +); hai solver 'full' và 'randomized' cho cosine = 1,000000 trên cả 5. `sklearn` còn dùng `ddof = 1` nên `explained_variance_` ra 6 chữ không phải 4,5 ($4,5 \times 4/3 = 6$), trong khi EVR vẫn đúng 0,9 / 0,1.

Kết quả 3 · dạng đóng của phương sai theo góc chiếu, và tổng hai đường cong là hằng số

Đặt $w = (\cos \theta, \sin \theta)$. Khai triển $w^T C w = (5/2)(\cos^2 \theta + \sin^2 \theta) + 2 \cdot (2 \sin \theta \cos \theta) = 5/2 + 2 \sin 2\theta$ — ba dòng, không cần nhân từ Lagrange. Cực đại 9/2 tại $\theta = 45^\circ$ (vì $2\theta = 90^\circ$), cực tiểu 1/2 tại 135° ; đây là tối ưu TOÀN CỤC trên vô hạn hướng, không chỉ là so hai ứng viên. Sai số dựng lại có dạng bù: $Err(\theta) = \text{trace}(C) - \text{Var}(\theta) = 5/2 - 2 \sin 2\theta$, đúng theo định lý Pythagoras vì phần giữ và phần bỏ vuông góc nhau. Hệ quả: $\text{Var}(\theta) + Err(\theta) = 5$ với MỌI θ — hai đường cong cộng lại thành một đường thẳng nằm ngang, và đó là hình quan trọng nhất của buổi: cực đại phương sai và cực tiểu sai số dựng lại là MỘT bài toán. Ba điều kiện để sự tương đương ấy còn đúng: phép biến đổi tuyến tính · khoảng cách đo bằng chuẩn Euclid bình phương · dữ liệu đã tâm hoá. Đổi sang chuẩn L1 thì kết luận sai. Nếu quên tâm hoá, đại lượng bị cực đại hoá trở thành $\text{Var}(z) + (\mu^T w)^2$, số hạng thứ hai chỉ đo đám mây nằm xa gốc bao nhiêu.

Kết quả 4 · sai số dựng lại trung bình bằng đúng tổng các trị riêng bị bỏ

Toạ độ mới trên trục thứ nhất: $z_1(A) = z_1(B) = -3/\sqrt{2} \approx -2,121320$ và $z_1(C) = z_1(D) = 3/\sqrt{2}$; trên trục thứ hai: $-1/\sqrt{2}, +1/\sqrt{2}, -1/\sqrt{2}, +1/\sqrt{2}$. Phép kiểm 4 (mạnh nhất): phương sai cột toạ độ mới bằng đúng trị riêng — $(1/4) \cdot 4 \cdot (9/2) = 9/2$ và $(1/4) \cdot 4 \cdot (1/2) = 1/2 \checkmark$. Dựng lại từ MỘT con số: A và B cùng cho (7/2; 7/2), C và D cùng cho (13/2; 13/2), tất cả nằm trên trục thứ nhất. Sai lệch của cả bốn điểm đều là $(\pm 1/2; \mp 1/2)$, bình phương khoảng cách đều bằng 1/2 $\Rightarrow$ sai số dựng lại trung bình = $1/2 = \lambda_2$, đúng bằng trị riêng bị bỏ. Chấm điểm hai phương án lớp tự đề xuất bằng cùng thước đo ấy: 'giữ cột x' cho 5/2 · 'giữ cột y' cho 5/2 · 'x + y' cho 1/2 — phương án x + y chính là PCA sai khác hằng số $\sqrt{2}$, và 18.000 hướng quét trong lúc soạn bài không hướng nào cho dưới 1/2. Trên UCI HAR đẳng thức vẫn khớp: bỏ 498 thành phần cho sai số đo được 55,800142 và tổng trị riêng bị bỏ 55,800142 — khớp 6 chữ số thập phân.

Kết quả 5 · nén sinh ra bất biến: bốn điểm còn hai vị trí, và điều đó lặp lại trên dữ liệu thật

Trên hiện vật: A và B khác nhau trong dữ liệu gốc nhưng có cùng toạ độ mới $-3/\sqrt{2}$, nên sau khi nén xuống một chiều chúng không phân biệt được nữa; bốn điểm chỉ còn hai vị trí. A và C cách nhau $\sqrt{2}$ trong không gian gốc, chiếu lên hướng 135° thì khoảng cách còn 0 — phép chiếu trực giao chỉ làm khoảng cách co lại, không bao giờ giãn ra. Trên UCI HAR ở 2 chiều, hiện tượng ấy lặp lại có hậu quả đo được: ma trận nhầm lẫn của nearest-centroid trên tập test cho recall của NGÔI chỉ 0,0652 (nhận đúng 32 trên 491 cửa sổ), NGÔI bị dón vào cùng vùng với ĐÚNG và NẦM. Đổi lại, ranh giới động/tĩnh thì sạch tuyệt đối: 0/1.387 cửa sổ động bị gọi nhầm thành tĩnh, và một ngưỡng duy nhất trên PC1 tách động/tĩnh đúng 99,7824 % trên train và 99,8982 % trên test — PC1 gần như đúng bằng câu hỏi 'người này có đang di chuyển không', dù nó học mà không hề nhìn nhãn. Tăng lên 63 chiều cứu được NGÔI (recall 0,0652 $\rightarrow$ 0,6986) nhưng XUỐNG CẦU THANG gần như không nhúc nhích (0,5310 $\rightarrow$ 0,5738).

Kết quả 6 · tên bài thành số: bỏ 88,77 % số cột, giữ 90,05 % phương sai — hai thứ khác nhau

Bảng đánh đổi trên UCI HAR (StandardScaler $\rightarrow$ PCA $\rightarrow$ nearest-centroid, tập test chính thức): $k = 2$ giữ 57,36 % phương sai, độ chính xác 0,5283 · $k = 10 \rightarrow 70,82\%$ và 0,7564 · $k = 26 \rightarrow 80,18\%$ và 0,7995 · $k = 63 \rightarrow 90,05\%$ và 0,8113 · $k = 102 \rightarrow 95,08\%$ và 0,8205 · $k = 179 \rightarrow 99,02\%$ và 0,8222 · $k = 561 \rightarrow 100\%$ và 0,8225. Chọn $k = 63$: bỏ 498 cột (88,77 %), mất 1,12 điểm phần trăm, nhanh 4,8 lần (1-NN trên 2.947 cửa sổ: 0,252 s ở 561D so với 0,052 s ở 63D), ma trận train nhẹ còn 11,23 % (31,47 MB $\rightarrow$ 3,53 MB). PC1 một mình chiếm 50,7812 % phương sai — gấp 284,9 lần mức $1/561 = 0,1783\%$ của giả thuyết 'các cột độc lập' — nhưng PC1 là hỗn hợp của hàng trăm cột (cần 159 cột mới gom đủ nửa khối lượng w^2 , 339 cột cho 90 %), nên đừng đặt tên nghiệp vụ cho một thành phần chính. BA TIÊU CHÍ CHỌN k CHO BA ĐÁP SỐ, tỉ lệ 1 : 31 : 51 — khuỷu tay $k = 2$ (bước giảm EVR: 44,20 rồi 3,77 rồi từ PC3 trở đi dưới 1 điểm phần trăm) · ngưỡng 90 % phương sai $k = 63 \cdot 99\%$ độ chính xác của bản đầy đủ $k = 102$. BỐN CHỖ HỎNG: ① phương sai không phải thông tin — PC5 (EVR 1,89 %) cho 0,461486 trong khi PC2 (EVR 6,58 %) chỉ cho 0,283000, phương sai kém 3,48 lần nhưng chính xác hơn 1,63 lần; ② một điểm ngoại lai $E = (5+t, 5-t)$ lật trục đúng 90 độ tại $t = \sqrt{10} \approx 3,1623$ mà EVR_1 chỉ đổi từ 0,5233 sang 0,5455 — EVR không cảnh báo; ③ 'luôn chuẩn hoá trước PCA' SAI ở chính bộ này: chỉ tâm hoá cho $k = 34$ và độ chính xác 0,836105 (561D: 0,845266), còn StandardScaler cho $k = 63$ và 0,811334 (561D: 0,822531) — tệ hơn cả hai mặt, vì 561 cột đã cùng đơn vị và cùng miền, chuẩn hoá thổi cột std 0,0408 lên ngang cột std 0,7517 (tỉ số 18,42 lần) và có thể khuếch đại nhiễu — người soạn ghi rõ đây là NHẬN ĐỊNH cần kiểm thêm; ④ 12 điểm cách đều trên đường tròn cho $C = (1/2) \cdot I$, EVR 50/50, PCA không thấy được rằng dữ liệu chỉ có một bậc tự do. RÕ RẪI: fit trên train + test rồi mới tách cho $k = 65$ và

0,814048 so với cách đúng $k = 63$ và 0,811334 — chênh chỉ +0,002714, NHỎ, nhưng lý do cầm là logic của phép đánh giá chứ không phải độ lớn hậu quả. Chia sai đơn vị thì hậu quả tùy mô hình: chia theo DÒNG ngẫu nhiên thời 1-NN từ 0,833729 lên 0,949304 (+11,56 điểm) nhưng nearest-centroid lại giảm 0,811334 → 0,794028 (-1,73 điểm); đối chứng chia theo người ngẫu nhiên 21/9 gần bằng cách chính thức ⇒ nguyên nhân là chồng lấn 50 % trong cùng một người. HỒ SƠ DỮ LIỆU tự đếm lại: 10.299 dòng · 561 cột · train/test 7.352/2.947 · 21/9 người · 0 người ở cả hai bên · 0 ô trống · 0 giá trị ngoài $[-1, 1]$ · 281–409 cửa sổ mỗi người (train), 288–381 (test); trang UCI đúng cả năm mục — khác Bài 6 và Bài 8. Nhưng features.txt có 561 dòng chỉ chứa 477 tên khác nhau: 42 tên lặp 3 lần, ảnh hưởng 126 cột (303–502), toàn bộ là bandsEnergy() thiếu hậu tố trục X/Y/Z — 0/126 cặp trùng DỮ LIỆU, nên đó là lỗi ĐẶT TÊN, nhưng tra cột theo tên sẽ im lặng lấy nhầm. Tỷ lệ chia: 70,0000 % theo NGƯỜI nhưng 71,3856 % theo DÒNG, lệch 1,39 điểm. Bất biến gỡ lỗi: sau StandardScaler, tổng trị riêng phải bằng đúng d — đo được 561,000000000. Đáp án hai câu trắc nghiệm giờ thế: 'nén 561 xuống 2 thì điều nào CHẮC CHẮN đúng' → B (vẽ được lên mặt phẳng; A sai vì khoảng cách chỉ co lại, C sai vì 2 chiều cho 52,83 % còn 561 chiều cho 82,25 %, mất 29,42 điểm, D sai vì PC là tổ hợp của cả 561 cột); 'vì sao phải tâm hoá' → B; 'nếu không khoá độ dài w' → B. Thoả hiệp người soạn tự khai: bảng đánh đổi theo k dùng tập TEST để tính độ chính xác, đó là đề DẠY về đánh đổi chứ không phải quy trình chọn k đúng — quy trình đúng phải tách validation từ train theo nhóm. Món nợ để lại cho Bài 10: 9a — trục của PCA cố định sau khi fit và mù nhãn, ai học được phép biến đổi bám theo nhiệm vụ; 9b — cấu trúc cong, ai đuổi được nó ra.

Buổi 10 — Hơn đúng một mẫu, hay hơn năm trăm mẫu?

Kết quả 1 · mọi mô hình tuyến tính đúng tối đa 3 trên 4 điểm XOR — chứng minh, không phải do

Bốn điểm: (0,0)→0 · (0,1)→1 · (1,0)→1 · (1,1)→0. Bất biến affine: với MỌI $f(x_1, x_2) = w_1x_1 + w_2x_2 + b$, ta có $f(0,0) + f(1,1) = w_1 + w_2 + 2b = f(0,1) + f(1,0)$ — đẳng thức này không nói gì về XOR, nó là tính chất của chính lớp hàm affine, và vì thế nó mạnh. Nhưng nhãn XOR: $y(0,0) + y(1,1) = 0$ còn $y(0,1) + y(1,0) = 2$. Phản chứng: nếu một đường thẳng tách đúng cả bốn điểm thì $f(0,1) > 0$ và $f(1,0) > 0$ nên về phải dương, còn $f(0,0) < 0$ và $f(1,1) < 0$ nên về trái âm — hai vế bằng nhau mà trái dấu, mâu thuẫn. Vậy mọi mô hình tuyến tính sai ít nhất 1 trong 4 điểm. Ba đường số học độc lập xác nhận, mỗi đường một lưới khác nhau (nếu chỉ một lưới thì còn nghi ngờ được là lưới quá thô): vết cận bước 1/4 trên $[-3, 3] = 15.625$ mô hình, cao nhất 3/4 · vết cận bước 1/3 = 6.859 mô hình, cao nhất 3/4 · quét ngẫu nhiên liên tục trên $[-20, 20] = 200.000$ mô hình, cao nhất 3/4. Không đường nào đạt 4/4. Đây chính là món nợ (2) của Bài 9 ở dạng nhỏ nhất — 12 điểm trên đường tròn cho ma trận hiệp phương sai (1/2)-I và EVR 50/50 — nhưng ở đây kết luận mạnh hơn hẳn: không phải 'chưa tìm ra' mà là 'không tồn tại'. Đáp án trắc nghiệm đầu buổi (vì sao không ai vẽ được?) → B, vì không tồn tại đường thẳng nào và chứng minh được; A, C, D đều là những lời giải thích người ta thật sự đưa ra khi gặp bài này lần đầu.

Kết quả 2 · đặc trưng ẩn tuyến tính có hiệp phương sai bằng ĐÚNG 0 với nhãn XOR; đặc trưng gây khúc thì không

Tầng ẩn cho sẵn: $W1 = [[1,1],[1,1]]$, $b1 = (0, -1)$, tức $h1 = \text{ReLU}(x1 + x2)$ và $h2 = \text{ReLU}(x1 + x2 - 1)$. Bảng tầng ẩn cho bốn điểm A, B, C, D: $h = (0,0) \cdot (1,0) \cdot (1,0) \cdot (2,1)$. Cột $h2$ chỉ nhận HAI giá trị (0 ở A, B, C và 1 ở D) trong khi $h1$ có ba giá trị 0, 1, 2. CẢNH BÁO CẤU CHỮ — bản đầu người soạn viết 'ReLU đã cắt ba giá trị âm', SAI: đầu vào của ReLU ở bốn điểm là -1, 0, 0, +1, nên chỉ MỘT điểm (A) bị cắt thật, còn B và C nằm ĐÚNG tại điểm gãy, nơi $\text{ReLU}'(0)$ không tồn tại (đạo hàm trái 0, đạo hàm phải 1; PyTorch và TensorFlow đều quy ước trả về 0). Đây là lần thứ ba trong mười buổi người soạn sai theo cùng một kiểu — sai MỨC ĐỘ chứ không sai công thức (Bài 7: 'rò rỉ làm điểm số tăng vọt'; Bài 9: 'hai khối không lẫn nhau một dòng nào', thật ra bất đối xứng 0 % / 0,51 %) — và cả ba lần đều bị bắt bởi phép kiểm ĐỊNH TÍNH, không phải phép kiểm số học. Hai hiệp phương sai, tính bằng bút với y trung bình = 1/2: $\text{cov}(h1, y) = (+1/2 + 0 + 0 - 1/2)/4 = 0$ CHÍNH XÁC, không phải làm tròn — hai số hạng khác 0 triệt tiêu nhau; $\text{cov}(h2, y) = (1/8 - 1/8 - 1/8 - 3/8)/4 = -1/8$, dấu âm vì chỉ điểm (1,1) có $h2 = 1$ và nhãn của nó là 0. Tổng quát: với mọi $u = a \cdot x1 + b \cdot x2 + c$ thì $\text{cov}(u, y) = 0$ trên XOR — đặc trưng tuyến tính không mang tin, phép gây khúc là thứ DUY NHẤT tạo ra thông tin mà mô hình tuyến tính nhìn thấy được. Đáp án câu hỏi 'số 0 ấy nói lên điều gì' → B: $h1$ không có quan hệ TUYẾN TÍNH với nhãn, nhưng vẫn có ích khi đi cùng $h2$ (Kết quả 5 bác bỏ mỗi như A). D sai vì bằng 0 không phải độc lập thống kê.

Kết quả 3 · gradient tại khối tạo bằng (0 ; 1/8) — thuật toán dồn toàn bộ việc học vào hướng phi tuyến

Khởi tạo tầng ra bằng 0: $W2 = (0,0)$, $b2 = 0 \Rightarrow z = 0$ và $p = \sigma(0) = 1/2$ ở MỌI điểm, bất kể h bằng bao nhiêu. (Khởi tạo 0 hợp lệ ở đây vì chỉ học tầng ra và tầng ra có đúng một đơn vị; khởi tạo cả một tầng ẩn bằng 0 thì mọi đơn vị trong tầng có cùng gradient và mãi mãi bằng nhau — mạng m đơn vị co lại thành mạng 1 đơn vị, đó là lý do thư viện luôn khởi tạo ngẫu nhiên.) Hai công thức duy nhất cần cho toàn bộ phần tính tay, lấy từ đạo hàm của cặp softmax + cross-entropy: $\partial L / \partial w2j = \langle (p - y) \cdot h_j \rangle$ và $\partial L / \partial b2 = \langle p - y \rangle$. Với $K = 2$ thì softmax TRÙNG sigmoid và đạo hàm $\partial L / \partial z = p - y$ chính là công thức cập nhật của hồi quy logistic ở Bài 5 — 'sai bao nhiêu thì sửa bấy nhiêu'. Ở khởi tạo, $p - y$ chỉ nhận $\pm 1/2$, nên: $\partial L / \partial w21 = (0 - 1/2 - 1/2 + 1)/4 = 0$ ĐÚNG BẰNG 0 (đi một bước với BẤT KỲ tốc độ học nào, $w21$ vẫn nằm nguyên tại 0) · $\partial L / \partial w22 = (1/2 \cdot 1)/4 = 1/8$, chỉ một số hạng khác 0 vì D là điểm duy nhất có $h2 \neq 0$ · $\partial L / \partial b2 = (1/2 - 1/2 - 1/2 + 1/2)/4 = 0$, bằng 0 vì nhãn cân bằng. Vậy $\partial L / \partial W2 = (0 ; 1/8)$. PHÉP KIỂM CHÉO: gradient bằng ÂM hiệp phương sai — 0 khớp 0, và +1/8 khớp +1/8 — hai đường đi tới từ hai ngành khác nhau (thống

kê mô tả và giải tích), không dùng chung giả định nào. NHỮNG đẳng thức ấy chỉ đúng khi y trung bình = 1/2: phân ví dụ đôi nhãn thành (0,1,1,1) cho y trung bình 3/4, khi đó $-\text{cov}(h_2, y) = -1/16$ trong khi $\partial L / \partial w_{22} = -1/8$, KHÔNG khớp; gradient vẫn tính được bình thường, chỉ có phép kiểm chéo là mất hiệu lực — phải biết điều đó TRƯỚC khi dựa vào nó.

Kết quả 4 · một bước gradient: mất mát $\ln 2 = 0,693147$ xuống 0,598176, và chỉ một tham số nhúc nhích

$L_0 = -\ln(1/2) = \ln 2 = 0,693147$ vì cả bốn điểm cùng có $p = 1/2$; đây là mốc của mô hình MŨ trên bài 2 lớp, mọi mất mát lớn hơn nó nghĩa là tệ hơn tung đồng xu. Mốc tổng quát: K lớp cân bằng $\Rightarrow$ mốc mù là $\ln K$, nên đáp án câu trắc nghiệm về bài 10 lớp là C, $\ln 10 = 2,302585$ (A, B, D là mồi nhử; hỏi ngược cho bài nhị phân ra $\ln 2 = 0,693147$). Chọn tốc độ học $\eta = 8$ không phải vì tối ưu mà vì $8 \times 1/8 = 1$ cho số nguyên: $W_2 \leftarrow (0,0) - 8 \cdot (0, 1/8) = (0, -1)$, $b_2 \leftarrow 0$. Chỉ w_{22} đổi; w_{21} đứng yên vì gradient bằng 0, b_2 đứng yên vì nhãn cân bằng — đây là đáp án của dự đoán ② mà lớp viết ra giấy trước khi tính. Sau bước ấy: $z = (0, 0, 0, -1)$ nên $p = (0,5 ; 0,5 ; 0,5 ; 0,268941)$, CHỈ điểm D được quyết, ba điểm còn lại vẫn đúng $p = 1/2$ — mô hình chưa có gì để nói về chúng, và điều này quan trọng hơn tin 'mất mát đã giảm'. $L_1 = [3 \cdot \ln 2 + (-\ln(1 - 0,268941))]/4 = 0,598176$, giảm 0,094971, tức 13,7 % của L_0 . PHÉP KIỂM RẼ NHẤT TRONG HỌC SÂU: L_1 phải nhỏ hơn L_0 với η đủ nhỏ; nếu tăng thì hoặc sai dấu cập nhật hoặc η quá lớn. Tăng η thì mất mát giảm thêm nhưng có một BỨC TƯỜNG ở $3 \cdot \ln 2/4 = 0,519860$ — một bước chỉ động được đúng MỘT tham số, ba điểm kia nằm ngoài tầm với. Ta dừng bút ở đây vì từ bước 2 trở đi p khác nhau giữa các điểm $\Rightarrow$ xuất hiện $\sigma(-1)$, $\sigma(-2)$ và hết phân số; đến bước 200 thì không ai tính tay nổi, và cũng không cần.

Kết quả 5 · nghiệm đích $W_2 = (2, -4)$, $b_2 = -1$ cho 4/4 — và nó dùng cả đặc trưng có hiệp phương sai 0

$z = 2h_1 - 4h_2 - 1$ cho bốn giá trị $z = -1, +1, +1, -1 \Rightarrow p = 0,268941 \cdot 0,731059 \cdot 0,731059 \cdot 0,268941$, đúng cả bốn điểm, $L = 0,313262$ (còn 45,2 % của L_0). Mọi $|z| = 1$: bốn điểm cách ranh giới đúng bằng nhau — bài toán được giải một cách CÂN ĐỐI. Điểm đắt nhất: hệ số của h_1 bằng 2, KHÁC 0, dù $\text{cov}(h_1, y) = 0$ — đây là bằng chứng cứng bác bỏ ý 'đặc trưng có hiệp phương sai 0 thì bỏ được'. Hệ số của h_2 bằng -4 , âm và lớn, khớp dấu của $\text{cov}(h_2, y) < 0$. Nghiệm KHÔNG duy nhất: nhân cả ba số với 3 vẫn đúng 4/4; chỉ dấu và tỉ lệ là cố định. Trong không gian ẩn, (0,1) và (1,0) TRÙNG KHÍT tại (1, 0) — mạng đã xoá thông tin phân biệt hai điểm ấy, và vì chúng cùng nhãn nên thông tin bị xoá là thông tin không cần (nói Bài 9: nén sinh ra bất biến; bất biến có lợi hay hại là tùy nhiệm vụ). Bỏ ReLU đi thì h_1, h_2 đều tuyến tính và mọi thứ sụp về $\leq 3/4$: kiểm nhanh trên chính bảng bốn dòng — với h_2 CHƯA qua ReLU, bốn giá trị là $-1, 0, 0, 1$ và tổng hai đầu bằng tổng hai giữa ($0 = 0$), đẳng thức affine còn nguyên; với h_2 ĐÃ qua ReLU, bốn giá trị là $0, 0, 0, 1$ và $1 \neq 0$, đẳng thức bị phá. RANH GIỚI NẪM Ở PHI TUYẾN, KHÔNG PHẢI SỐ LỚP — vì $W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2)$, đúng với 2, 10 hay 100 lớp. Máy xác nhận: `MLPClassifier(hidden_layer_sizes=(2,), relu, max_iter=20000)` cũng đạt 4/4 nhưng với bộ trọng số KHÁC hẳn, vì hoán vị đơn vị (m! cách) và co giãn dương (nhân hàng j của W_1 với $c > 0$, chia cột j của W_2 cho c) đều cho cùng một hàm — tập nghiệm là một họ liên tục. Hệ quả cho kiểm thử: ĐỪNG assert trọng số (`np.allclose(clf.coefs_[0], W1)`) sẽ hỏng dù mô hình hoàn toàn đúng), hãy assert HÀNH VI: số điểm đúng, dấu của z tại bốn điểm, hình dạng vùng quyết định. Bốn mốc bắt buộc để kiểm máy trước khi tin bất cứ con số nào ở nửa sau: bảng h (0,0)(1,0)(1,0)(2,1) · cặp hiệp phương sai 0 và $-1/8 \cdot \text{gradient}$ (0 ; 1/8) và 0 · mất mát 0,693147 $\rightarrow$ 0,598176. Gradient số bằng sai phân đối xứng ($\text{eps} = 1e-6$, sai số $O(\text{eps}^2)$) cho $[0,0, 0,125]$ — đường DUY NHẤT không dùng lại công thức $p - y$, nên nó kiểm được cả công thức lẫn cài đặt.

Kết quả 6 · tên bài thành số: +1 mẫu trên Digits nhưng +526 mẫu trên MNIST — biểu diễn quyết định DẤU

MỞ ĐẦU NGƯỜI ĐỔI: hồi quy logistic của Bài 5, không tăng ẩn nào, đạt 0,981481 = 530/540 trên Digits; sáu cặp nhãn nhiều nhất chỉ gộp lại 10/540 ảnh, nặng nhất là 8 $\rightarrow$ 1 (3 ảnh). Chạy lần đầu chưa dò gì, MẠNG THUA cả bốn cấu hình: MLP(32) 0,973333 (5 hạt: 0,970370–0,975926) · MLP(64) 0,978519 · MLP(256) 0,980741 · MLP(128,64) hai tầng ẩn 0,975556. NHỮNG SO SÁNH ẤY KHÔNG CÔNG BẰNG — logistic đã dò C từ trước, MLP thì chọn bừa; kết luận 'mạng thua' nói về QUY TRÌNH chứ không nói về MÔ HÌNH. Dò lại cả hai bằng cùng một quy trình (kiểm chứng chéo 5 phần trên train, 175 lần huấn luyện mất 44,9 giây, rồi chạy test ĐÚNG MỘT LẦN): logistic 5 cấu hình, CV 0,964207, test 0,981481 = 530/540; MLP((256,), $\alpha=1e-4$) 30 cấu hình, CV 0,980902, test 0,983333 = 531/540. Mạng thắng ĐÚNG 1 MẪU; CV nói hơn 0,016695 còn test nói hơn 0,001852 — validation phóng đại khoảng 9 lần. TIỀN ĐOÁN ① được xác nhận: `activation='identity'` (bỏ phi tuyến) cho 0,965926 so với `relu` 0,973333, chênh 0,007407 — định lý đúng tuyệt đối nhưng cái giá thực nghiệm NHỎ trên bộ này, trong khi trên XOR cái giá là cả một phần tư. TIỀN ĐOÁN ② trên MNIST cũng được xác nhận: logistic thắng trên 784 pixel 0,9256 · PCA(64) $\rightarrow$ logistic 0,9173 ($-0,0083, \leq 0$ đúng như tiên đoán vì PCA là phép chiếu tuyến tính, dù giữ 86,19 % phương sai) · MLP(128) 0,9782 ($+0,0526$) · PCA(64) $\rightarrow$ MLP 0,9823, cao nhất mọi cấu hình. BẢNG BA BỘ — chính là tên bài: Digits (đặc trưng NGƯỜI thiết kế, $n = 1.257$) 530 so với 531, +1 mẫu · HAR (561 đặc trưng người thiết kế, $n = 7.352$) 0,955887 so với 0,943785, MẠNG THUA · MNIST (784 pixel THÔ, $n = 60.000$) 9.256 so với 9.782, +526 mẫu. ĐỐI CHỨNG tách cỡ mẫu khỏi biểu diễn: trên pixel thô mạng thắng ở MỌI cỡ mẫu — $n = 1.257$ ($+0,0170$) · 5.000 ($+0,0319$) · 20.000 ($+0,0525$) · 60.000 ($+0,0528$); và cùng $n = 1.257$, cùng giao thức chưa dò, Digits cho $-0,002962$ còn MNIST cho $+0,0170$ — ĐỐI DẤU. Kết luận có điều kiện: biểu diễn quyết định DẤU, cỡ mẫu chỉ khuếch đại ĐỘ LỚN; mạng chỉ đáng khi biểu diễn có sẵn còn THÔ. BỐN CHỖ HỒNG, mỗi chỗ một số đo của chính buổi: ① mạng không tự động thắng (đo ba lần: +1 mẫu, thua, +526 mẫu; định lý xấp xỉ phổ quát nói mạng CÓ THỂ biểu diễn mọi

hàm liên tục, không nói bạn TÌM được hàm ấy từ dữ liệu hữu hạn bằng gradient descent) · ② quá khờ im lặng, và KHÔNG phải đặc sản của mạng: độ chính xác train = 1,000000 ở MỌI cấu hình kể cả logistic, nên cột ấy không mang một bit thông tin nào — thứ phải nhìn là KHOẢNG CÁCH train trừ test (MLP(32) 0,026667 · MLP(256) 0,019259 · MLP(128,64) 0,024444 · logistic 0,018519) · ③ chênh lệch nhỏ hơn nhiều thì không phải chênh lệch: MLP(32) qua 5 hạt dao động 0,005556, gấp 3,0 lần khoảng cách 0,001852 giữa hai mô hình đã dò kỹ $\Rightarrow$ kết luận trung thực là HAI MÔ HÌNH NGANG NHAU trên bộ này · ④ neuron này dò nét ngang' là DIỄN GIẢI chứ không phải phép đo — đơn vị không duy nhất (hoán vị và co giãn), đầu ra là tổ hợp của cả 32 đơn vị, và nổi Bài 9 nơi PC1 cần 159 cột mới đủ nửa khối lượng. BẦY PHỤ: chuẩn hoá giúp logistic (0,957407 $\rightarrow$ 0,981481, +0,024074) nhiều hơn giúp mạng (0,975556 $\rightarrow$ 0,978519, +0,002963) — NGƯỢC chiều với Bài 9 nơi chuẩn hoá làm PCA tệ đi; 'luôn chuẩn hoá' là quy tắc quá thô. CHIA CV: đáp án câu hỏi Digits và HAR có chia giống nhau không $\rightarrow$ B, HAR phải chia theo NGƯỜI (GroupKFold) vì các cửa sổ của cùng một người không độc lập; trên HAR đo được cái giá là hơn năm điểm phần trăm. Digits KHÔNG có mã người viết nên buộc phải GIẢ ĐỊNH các mẫu độc lập — giả định không kiểm được, và nếu sai thì cả 0,981481 lẫn 0,983333 đều lạc quan hơn thực tế. Cảnh báo cài đặt: MLPClassifier mặc định max_iter=200, khi chưa hội tụ vẫn trả về mô hình kèm ConvergenceWarning — đừng tắt cảnh báo, hãy kiểm clf.n_iter_. NHỮNG GÌ CỐ Ý KHÔNG DẠY: lan truyền ngược qua nhiều tầng, Adam và quán tính, dropout / batch norm / dừng sớm, CNN, Transformer, học chuyển giao, GPU — mọi kết luận hôm nay là kết luận ở QUY MÔ NHỎ. Món nợ giao lại: chạy đúng bằng ba bộ ấy với một mạng tích chập trên MNIST, cùng tập test 10.000 mẫu, xem 526 mẫu còn lại bao nhiêu và 218 lỗi của MLP giảm được bao nhiêu; điều kiện nộp là báo cáo cả kết quả xấu, nêu khoảng dao động qua ít nhất 5 hạt, tự nêu một lập luận phản bác chính mình, và không chạm tập test quá một lần.

PHỤ LỤC B — THUẬT NGỮ VIỆT-ANH

Gộp toàn học phần, xếp theo buổi. Tra nhanh khi đọc tài liệu tiếng Anh.

Buổi	Tiếng Việt	Tiếng Anh
1	vector	vector
1	số chiều	dimension
1	mã hoá một-nóng	one-hot
1	mã hoá nhiều-nóng	multi-hot
1	tích vô hướng	dot product
1	chuẩn L2	L2 norm
1	chuẩn hoá	normalization
1	độ tương đồng cosine	cosine similarity
1	biểu diễn dữ liệu	representation
1	hồ sơ người dùng	user profile
1	xếp hạng top-N	top-N ranking
1	người dùng mới chưa có dữ liệu	cold start
2	phân loại	classification
2	k láng giềng gần nhất	k-nearest neighbours
2	khoảng cách Euclid	Euclidean distance
2	khoảng cách Manhattan	Manhattan distance
2	đặc trưng	feature
2	chuẩn hoá	normalization
2	tập huấn luyện	training set
2	tập kiểm tra	test set
2	bỏ phiếu đa số	majority vote
2	siêu tham số	hyperparameter
2	độ chính xác	accuracy
2	độ bao phủ của một lớp	recall
3	ma trận nhầm lẫn	confusion matrix
3	dương tính giả	false positive
3	âm tính giả	false negative
3	độ chính xác	accuracy
3	độ chuẩn xác	precision
3	độ bao phủ	recall
3	điểm F1	F1 score
3	trung bình điều hoà	harmonic mean
3	ngưỡng quyết định	decision threshold
3	mô hình cơ sở	baseline
3	dữ liệu mất cân bằng	imbalanced data
3	khả năng tổng quát hoá	generalization
4	hồi quy tuyến tính	linear regression
4	phần dư	residual
4	hàm mất mát	loss function
4	sai số bình phương trung bình	mean squared error
4	sai lệch tuyệt đối trung bình	mean absolute error
4	hệ số xác định	coefficient of determination
4	nghiệm đóng	closed-form solution
4	thuật toán xuống dốc	gradient descent
4	tốc độ học (độ dài bước)	learning rate
4	đạo hàm riêng	partial derivative
4	ma trận Hessian	Hessian matrix
4	điều kiện số	condition number

5	hồi quy logistic	logistic regression
5	odds	—
5	log-odds	logit
5	hàm sigmoid	sigmoid function
5	hợp lý cực đại	maximum likelihood
5	log-loss (entropy chéo nhị phân)	binary cross-entropy
5	tỉ số odds	odds ratio
5	phương trình điểm số	score equations
5	ranh giới quyết định	decision boundary
5	hiệu chuẩn	calibration
5	tách hoàn hảo	separation
5	chính quy hoá	regularization
6	cây quyết định	decision tree
6	chỉ số Gini	Gini impurity
6	độ lợi thông tin	information gain
6	nhát cắt vuông góc trục	axis-aligned split
6	thuật toán tham lam	greedy algorithm
6	quá khớp	overfitting
6	cắt tỉa	pruning
6	tầm quan trọng của đặc trưng	feature importance
6	rừng ngẫu nhiên	random forest
6	lấy mẫu có hoàn lại	bootstrap
6	kiểm định chéo	cross-validation
6	bất biến với biến đổi đơn điệu	monotone invariance
7	rò rỉ dữ liệu	data leakage
7	bảng chéo	crosstab
7	chia theo thời gian	time-based split
7	chia phân tầng	stratified split
7	hàng trùng lặp	duplicate rows
7	dây chuyền xử lý	Pipeline
7	chuẩn hoá	StandardScaler
7	điền khuyết	imputation
7	kiểm chứng chéo	cross-validation
7	dịch chuyển phân phối	distribution shift
7	mã hoá one-hot	one-hot encoding
7	mã hoá mục tiêu	target encoding
8	học không giám sát	unsupervised learning
8	phân cụm	clustering
8	K-means	—
8	tâm cụm	centroid
8	tổng bình phương trong cụm	WCSS
8	thuật toán Lloyd	Lloyd's algorithm
8	khởi tạo k-means++	k-means++
8	nghiệm cục bộ	local optimum
8	quy tắc khuỷu tay	elbow method
8	silhouette	—
8	chỉ số Rand hiệu chỉnh	adjusted Rand index
8	gần đây · tần suất · giá trị	RFM
9	phân tích thành phần chính	principal component analysis
9	giảm chiều	dimensionality reduction
9	tâm hoá	centering
9	ma trận hiệp phương sai	covariance matrix
9	trị riêng	eigenvalue

9	vector riêng	eigenvector
9	thành phần chính	principal component
9	toạ độ trên trục mới	score
9	tỉ lệ phương sai giải thích	explained variance ratio
9	sai số tái tạo	reconstruction error
9	chuẩn hoá z	standardization
9	phân rã giá trị suy biến	singular value decomposition
10	mạng neuron nhiều lớp	multilayer perceptron
10	tầng ẩn	hidden layer
10	tầng ra	output layer
10	hàm kích hoạt	activation function
10	ReLU	—
10	softmax	—
10	mất mát cross-entropy	cross-entropy loss
10	học biểu diễn	representation learning
10	siêu tham số	hyperparameter
10	kiểm chứng chéo	cross-validation